

**DCA**

Departamento de Engenharia de  
Computação e Automação Industrial



Faculdade de Engenharia  
Elétrica e de Computação



# Introdução a Outras Técnicas de Computação Natural



Guilherme Palermo Coelho

Fernando J. Von Zuben

# Conteúdo Geral

- Este tópico do curso está subdividido em:
  - Introdução;
  - Inteligência coletiva (ACO);
  - Inteligência coletiva (PSO);
  - Sistemas imunológicos artificiais
  - Referências bibliográficas

# Computação Natural

- **Computação Natural** é a junção de ideias presentes na natureza com a computação:
  - Desenvolvimento de novas técnicas para a solução de problemas complexos (*computação inspirada na natureza ou bioinspirada*);
  - Uso de computadores para sintetizar formas, comportamentos e padrões similares aos naturais (*simulação da natureza*);
  - Uso de novos materiais naturais (além de silício) para fazer computação (*biocomputação*).

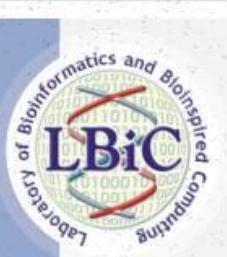
# Computação Natural

- **Computação Natural** é a junção de idéias presentes na natureza com a computação:
  - Desenvolvimento de novas técnicas para a solução de problemas complexos (*computação inspirada na natureza ou bioinspirada*);
  - Uso de computadores para sintetizar formas, comportamentos e padrões similares aos naturais (*simulação da natureza*);
  - Uso de novos materiais naturais (além de silício) para fazer computação (*biocomputação*).



# Complexidade de Problemas Computáveis

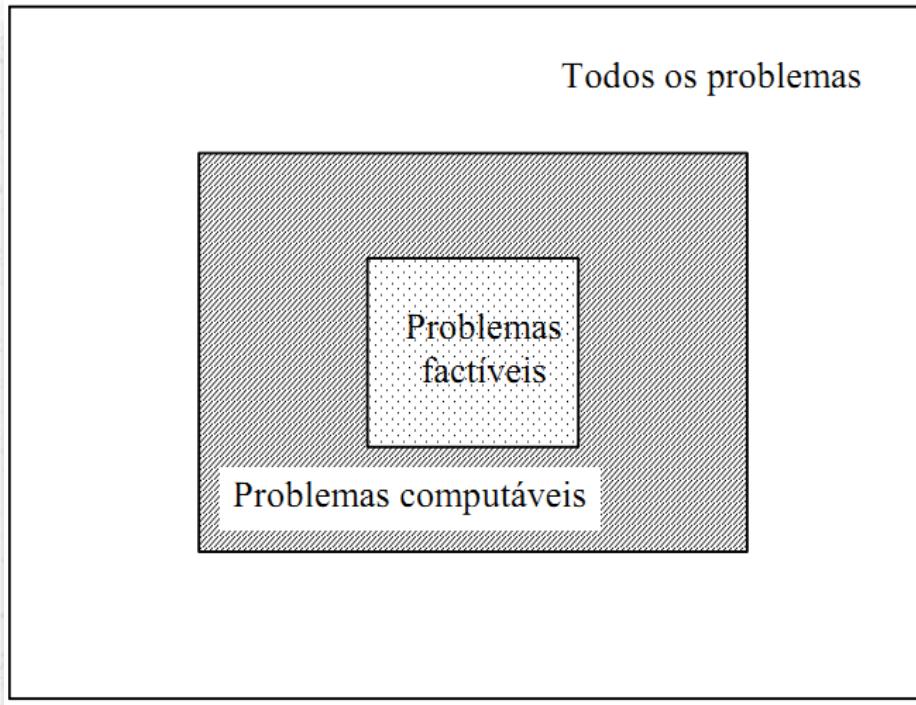
- **Problemas computáveis:**
  - Aqueles para os quais é possível fornecer um algoritmo que leve à sua solução;
- Tomando o conceito de **espaço de soluções candidatas**:
  - Resolver um problema → encontrar a solução ótima neste espaço;
- Sendo assim, o algoritmo de solução envolve uma **busca pela solução ótima**, razão pela qual o **espaço de soluções** candidatas também é denominado de **espaço de busca**.



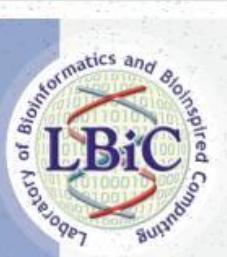
# Complexidade de Problemas Computáveis

- Neste cenário, a **complexidade** dos problemas computáveis está associada à quantidade de memória e ao tempo de processamento necessários para se chegar à solução explorando este espaço de busca.
- Se uma dessas quantidades, ou ambas, não forem tratáveis computacionalmente, então diz-se que o problema é **infactível**.

# Complexidade de Problemas Computáveis



- Da Figura 1, percebe-se que os grandes desafios da computação estão no tratamento de problemas que pertencem à região hachurada, ou seja, problemas computáveis e infactíveis.

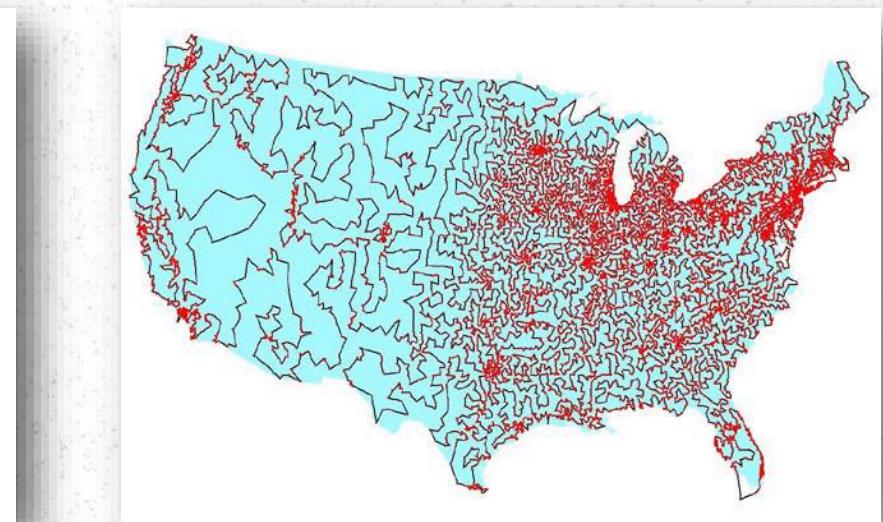
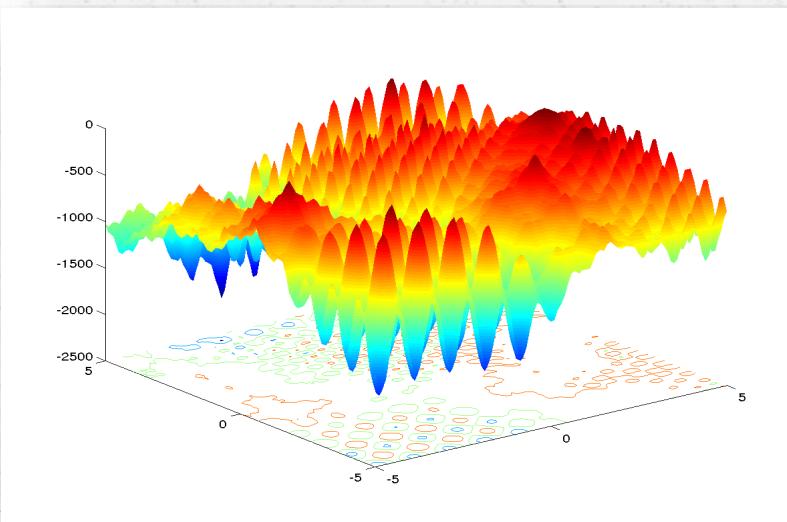


# Complexidade de Problemas Computáveis

- Se os algoritmos que garantem a obtenção da solução ótima são infactíveis para problemas na região hachurada, então como resolvê-los?
  - **Proposta:** Abrir mão da garantia de obtenção da solução ótima em prol da factibilidade.
  - Uma boa solução, não necessariamente a ótima, é melhor que nenhuma solução ou que uma solução tomada aleatoriamente do espaço de busca.
  - A ideia é propor algoritmos que explorem o espaço de busca de forma eficaz, visando localizar soluções de boa qualidade, que até podem corresponder à solução ótima.

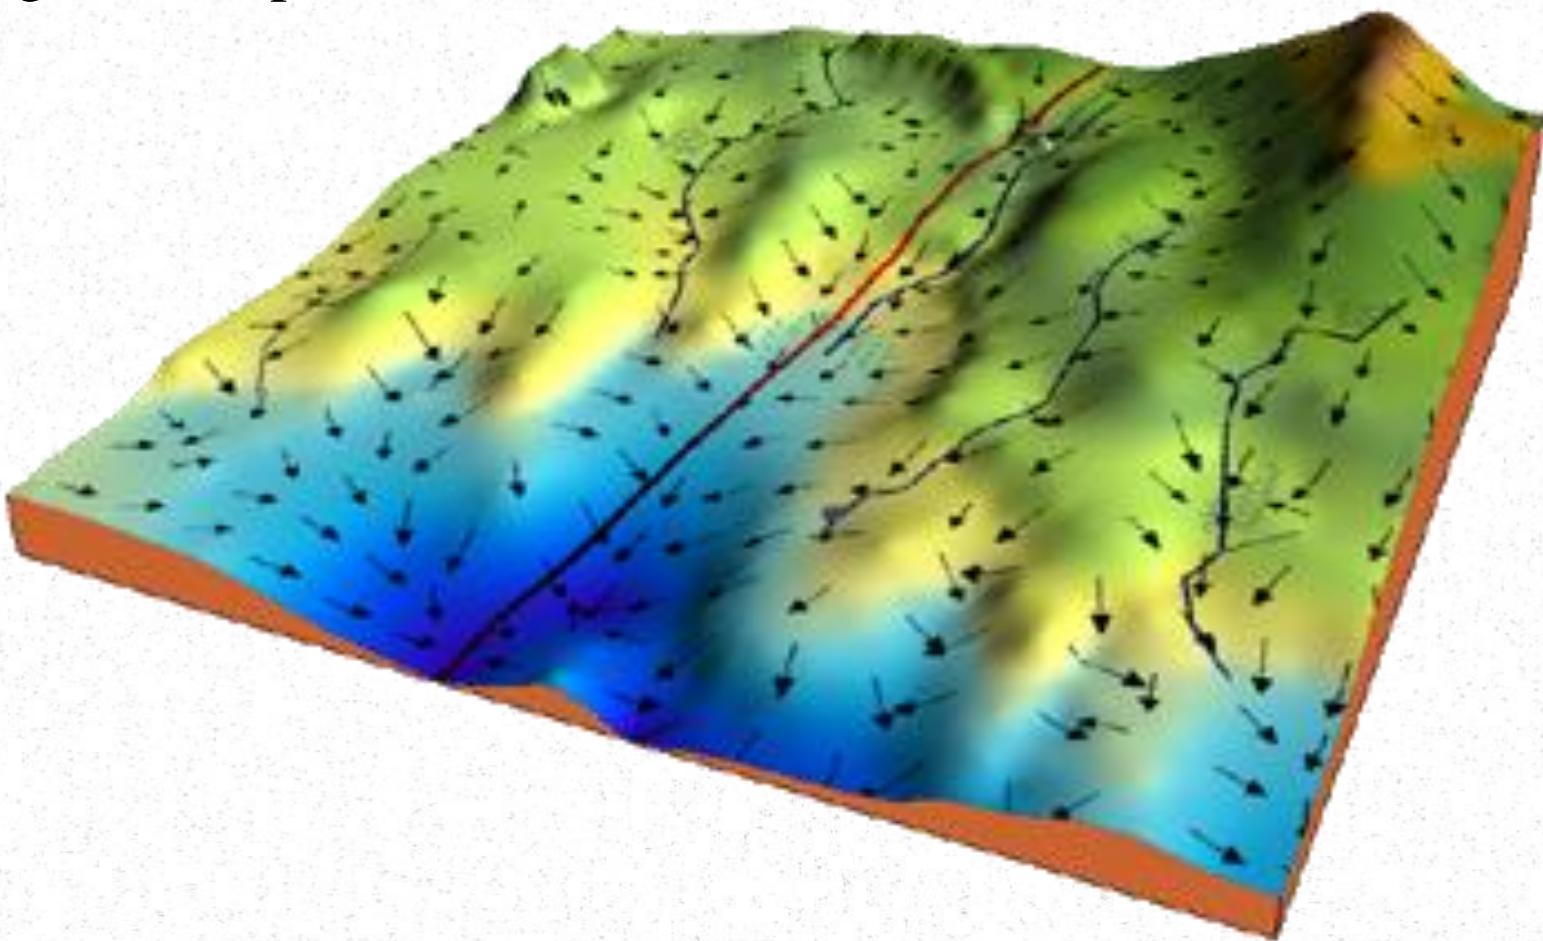
# Complexidade de Problemas Computáveis

- Exemplos de problemas computáveis e não-factíveis:
  - Em **espaços contínuos**, otimização de problemas multimodais → não-lineares, não-convexos, não-diferenciáveis.
  - Em **espaços discretos**, problemas combinatórios em geral.
    - Problema do caixeiro viajante (TSP).



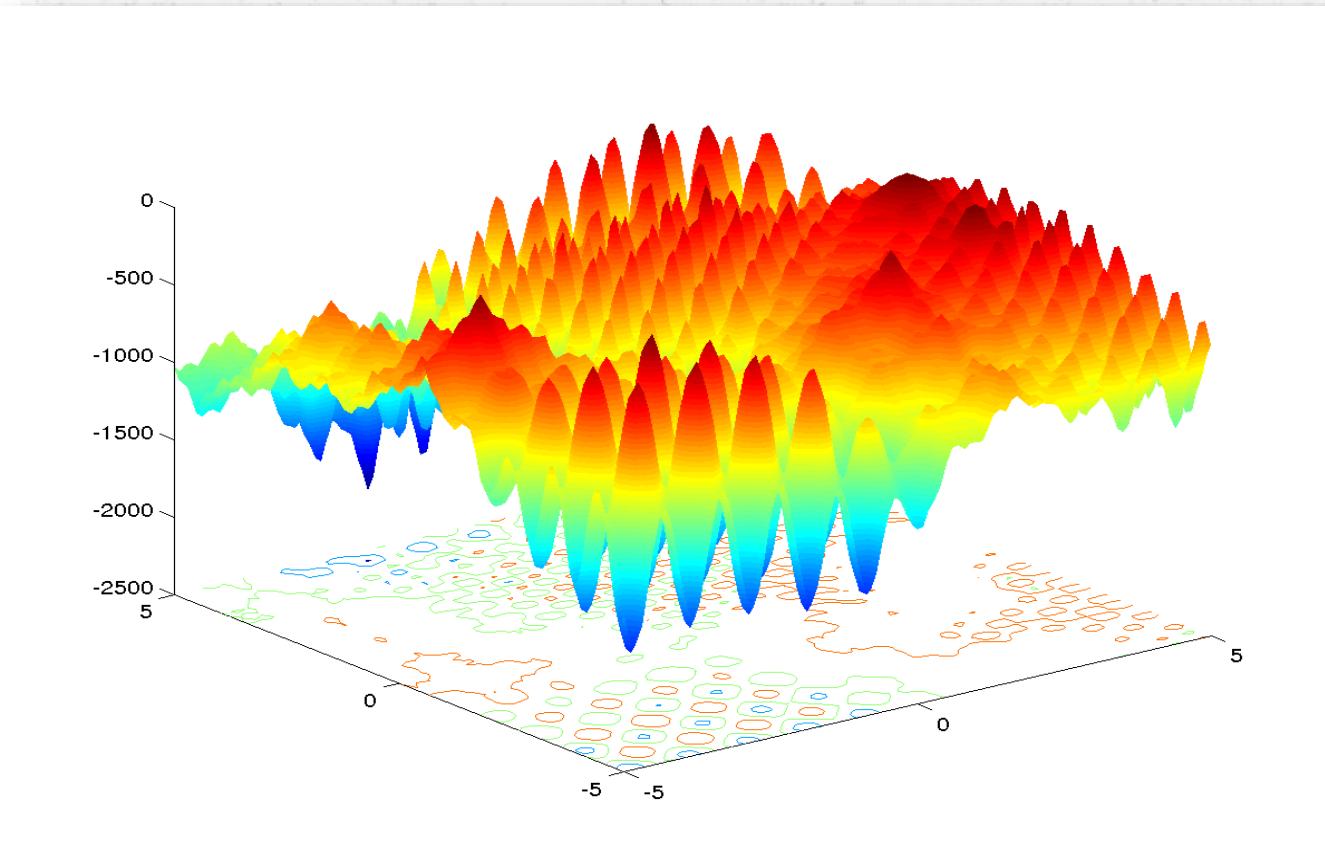
# **Gradiente em espaços contínuos**

Mesmo no caso de superfícies diferenciáveis, a aplicação do gradiente pode não ser indicada. É indicada no caso abaixo.



# Gradiente em espaços contínuos

Mesmo no caso de superfícies diferenciáveis, a aplicação do gradiente pode não ser indicada. Não é indicada no caso abaixo.



# Meta-heurísticas

- Meta-heurísticas compreendem metodologias de busca em espaços de soluções candidatas capazes de gerenciar operadores computacionais de busca local e de busca global, promovendo robustez e eficácia na busca de soluções (GLOVER & KOCHENBERGER, 2002).
- Geralmente **NÃO** apresentam as seguintes propriedades:
  - Garantia de obtenção da solução ótima;
  - Garantia de convergência;
  - Garantia de custo máximo para se chegar a uma solução.

# Meta-heurísticas

- **Abordagens populacionais:**
  - Ex.: Técnicas de computação bioinspirada;
- **Abordagens não-populacionais:**
  - Ex.: *simulated annealing* (KIRKPATRICK et al., 1983) e busca tabu (GLOVER & LAGUNA, 1997).

# Computação Bioinspirada

- Toma os seres vivos como fonte de inspiração para o desenvolvimento de técnicas de solução de problemas;
- Busca desenvolver ferramentas (algoritmos) para a solução de problemas complexos;
- Principais frentes:
  - Redes Neurais Artificiais;
  - Computação Evolutiva;
  - Inteligência Coletiva;
  - Sistemas Imunológicos Artificiais.



**Já visto**  
**Já visto**  
**Tratados aqui**

# Computação Bioinspirada

## Quando usar técnicas de computação bioinspirada?

- Quase que invariavelmente, as técnicas de computação bioinspirada são **técnicas alternativas**;
- Isso indica que existem outras maneiras para se resolver um mesmo problema;
- É preciso avaliar com cuidado se há ou não a necessidade de aplicação de técnicas de computação bioinspirada a um dado problema.

# Computação Bioinspirada

## Quando usar técnicas de computação bioinspirada?

- A computação bioinspirada pode ser usada quando:
  - O problema a ser resolvido é complexo (grande número de variáveis, grande quantidade de possíveis soluções, etc.);
  - Não é possível garantir que uma solução encontrada é ótima, mas é possível criar **métricas de comparação** entre soluções candidatas;
  - O problema a ser resolvido não pode ser (apropriadamente) modelado. Em alguns casos, pode-se empregar **exemplos** para **ensinar** o sistema a resolver o problema;
  - Uma única solução para o problema não é suficiente, ou seja, quando **diversidade** é importante.

# INTELIGÊNCIA COLETIVA



# Inteligência Coletiva

- Do inglês *Swarm Intelligence*: inteligência coletiva ou de enxame;



- O termo *enxame* (ou *coletivo*) se refere de forma genérica a qualquer coleção estruturada de agentes capazes de interagir:
  - Enxame de abelhas;
  - Colônia de formigas;
  - Revoada de pássaros
  - Cardume de peixes ...

# Inteligência Coletiva

- A inteligência de enxame inclui qualquer tentativa de projetar algoritmos ou dispositivos distribuídos de solução de problemas inspirados no comportamento coletivo de insetos sociais e outras sociedades animais.
- A inteligência coletiva é uma propriedade de sistemas compostos por agentes não (ou pouco) inteligentes e com capacidade individual limitada, capazes de apresentar comportamentos coletivos inteligentes.

# In inteligência Coletiva

## Algumas propriedades da inteligência coletiva:

- *Proximidade*: os agentes devem ser capazes de interagir;
- *Qualidade*: os agentes devem ser capazes de avaliar seus comportamentos;
- *Diversidade*: permite ao sistema reagir a situações inesperadas;
- *Estabilidade*: nem todas as variações ambientais devem afetar o comportamento de um agente;
- *Adaptabilidade*: capacidade de se adequar a variações ambientais.

# Inteligência Coletiva

- Um **sistema de enxame** é aquele composto por um conjunto de agentes capazes de interagir entre si e com o meio ambiente.
- A **inteligência de enxame** é uma propriedade emergente de um sistema coletivo que resulta de seus princípios de proximidade, qualidade, diversidade, estabilidade e adaptabilidade.
- Característica comum a todos os algoritmos baseados em inteligência coletiva: *população de indivíduos capazes de interagir entre si e com o ambiente*.

# Inteligência Coletiva

## Técnicas e Aplicações Populares:

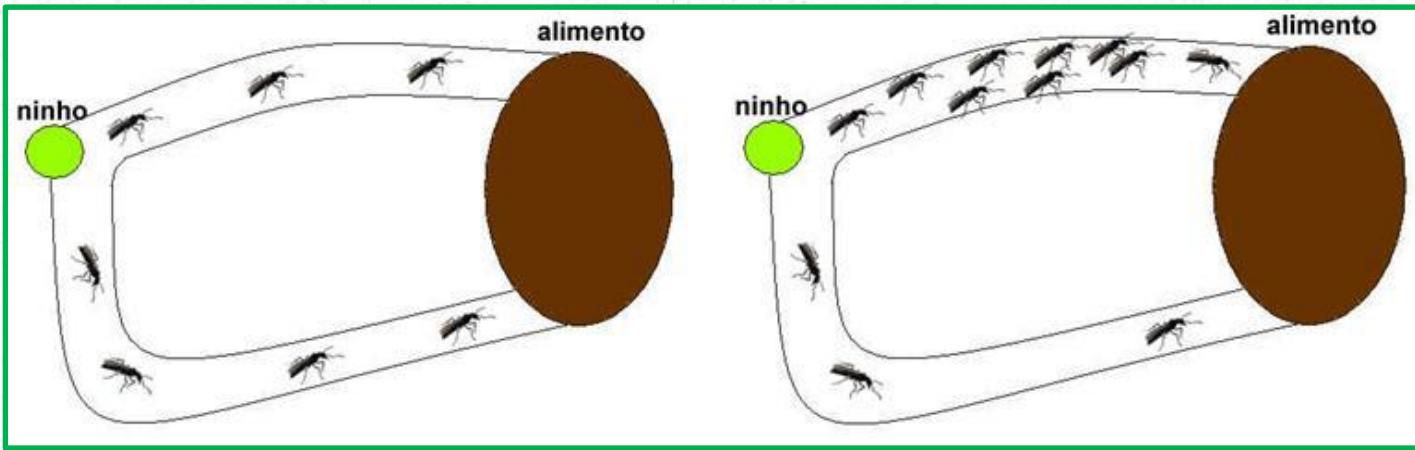
- Otimização por colônia de formigas (ACO): se baseia no comportamento de formigas em busca por alimentos.
- Otimização por enxame de partículas (PSO): busca criar uma simulação do comportamento social humano, particularmente a capacidade humana de processar conhecimento.

# Otimização por Colônia de Formigas

- Baseia-se no comportamento das formigas na busca por alimento;
- Inicialmente cada formiga segue um caminho aleatório, explorando o ambiente;
- Ao encontrar a fonte de alimento, mesmo que por diferentes caminhos, após algum tempo observa-se a tendência de se estabelecer a *menor rota entre o alimento e o ninho*;
- Cada formiga utiliza *comunicação indireta* para indicar para as outras o quanto bom foi o caminho que ela escolheu;
- Para isso elas espalham uma substância chamada *feromônio*.



# Otimização por Colônia de Formigas



- Como as formigas que escolheram o **menor caminho** completavam o percurso **mais rápido** que as outras, elas acabavam depositando uma **maior quantidade de feromônio** nesse caminho em relação ao outro, em um mesmo intervalo de tempo;
- Logo, em um determinado momento, a **intensidade do feromônio** no caminho mais curto estará tão alta que quase todas as formigas seguirão por ele.

# Otimização por Colônia de Formigas

- Em 1992, Dorigo percebeu que as formigas resolviam um problema muito similar ao do **caixeiro viajante (TSP)**;
- Inspirado nesse comportamento, resolveu modelá-lo computacionalmente e verificar como o algoritmo se comportava para algumas instâncias conhecidas do problema.



<https://www.marginallyclever.com/2012/05/drawbot-added-traveling-salesman-problem-and-gcode-generation/>

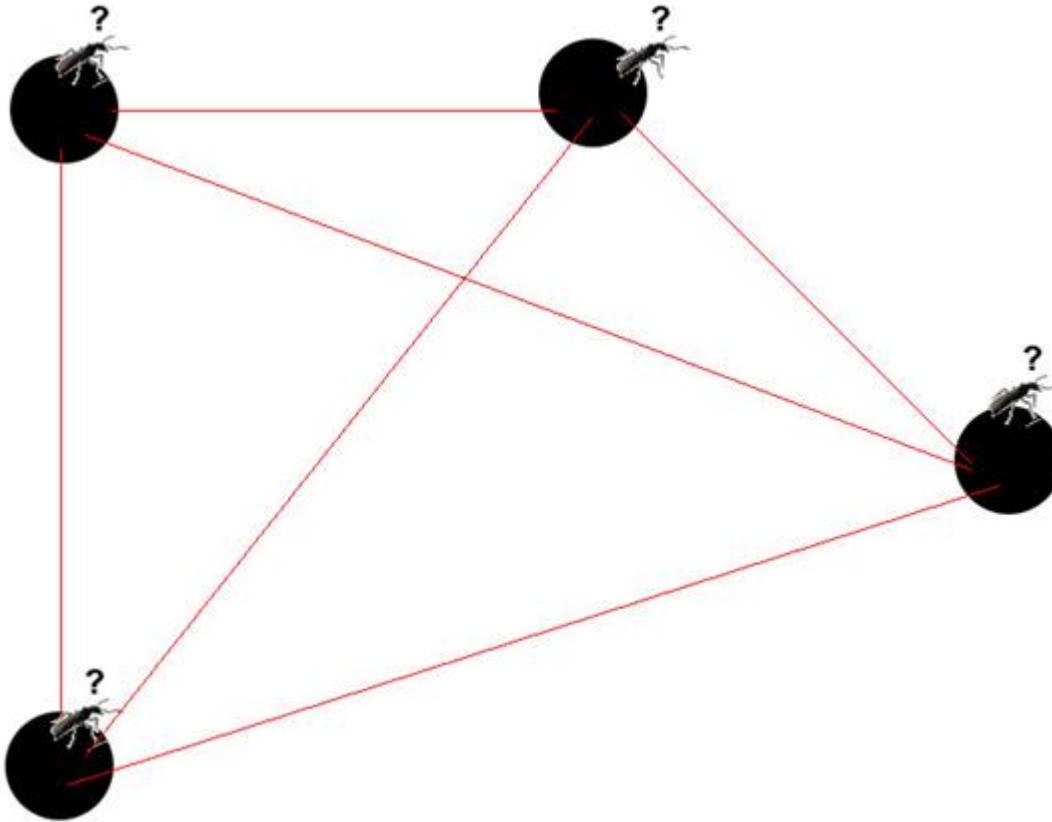
- O problema do caixeiro-viajante corresponde a encontrar a **menor rota que passe por  $N$  cidades**, sendo que cada cidade deve ser visitada **uma única vez**.

# Problema do Caixeiro Viajante

- A solução ótima pode ser intuitiva para instâncias pequenas do problema → **busca exaustiva**:
  - Problema com 8 cidades:
  - $(8-1)!/2 = 2520$  possibilidades → **Fácil de resolver!**
- Aumentando-se a complexidade do problema → busca exaustiva se torna inviável:
  - Problema com 20 cidades:
  - $(20-1)!/2 = 60.822.550.204.416.000$  possibilidades → **Complicado!**
  - Problema típico com 100 cidades:
  - $(100-1)!/2 = 4,5 \times 10^{155}$  possibilidades!!!
  - $1,5 \times 10^{135}$  anos de processamento em uma máquina de 10THz;
  - Idade estimada do universo =  $13,7 \times 10^9$  anos.

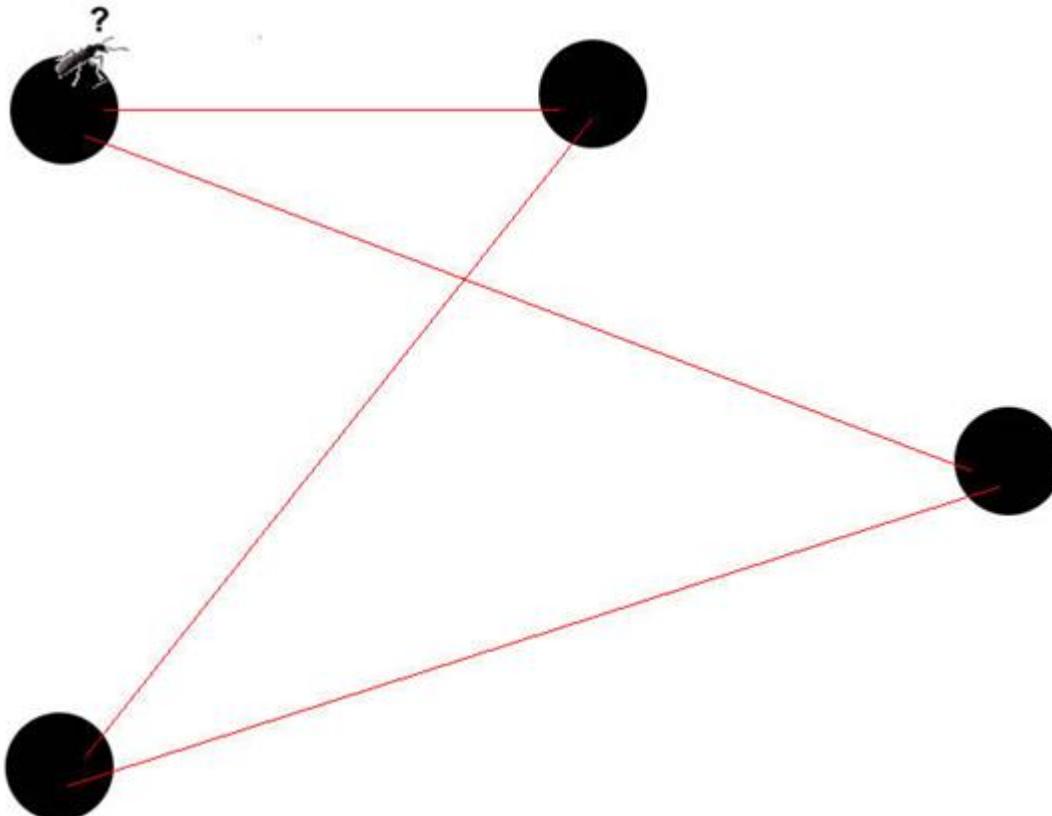
# Otimização por Colônia de Formigas

- Dado um grafo com  $n$  vértices, colocar uma formiga artificial em cada um deles;



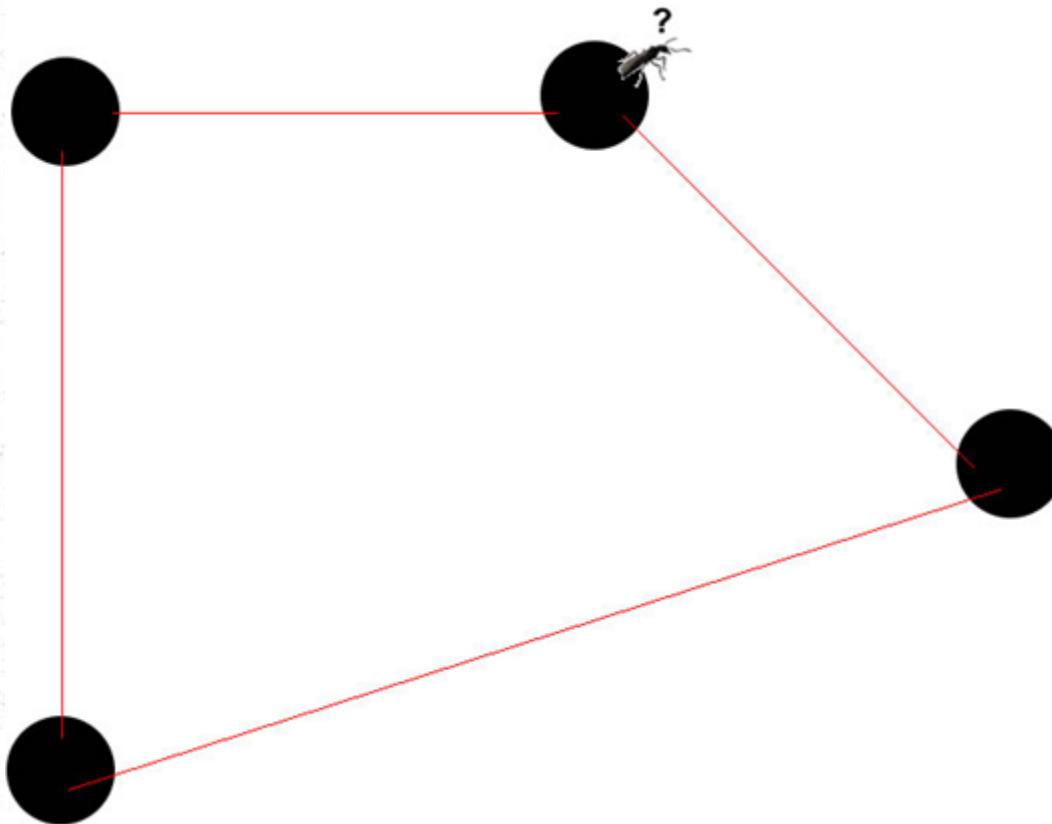
# Otimização por Colônia de Formigas

- Cada formiga traça um caminho seguindo uma fórmula *probabilística* em função do *feromônio* presente em cada aresta do grafo;



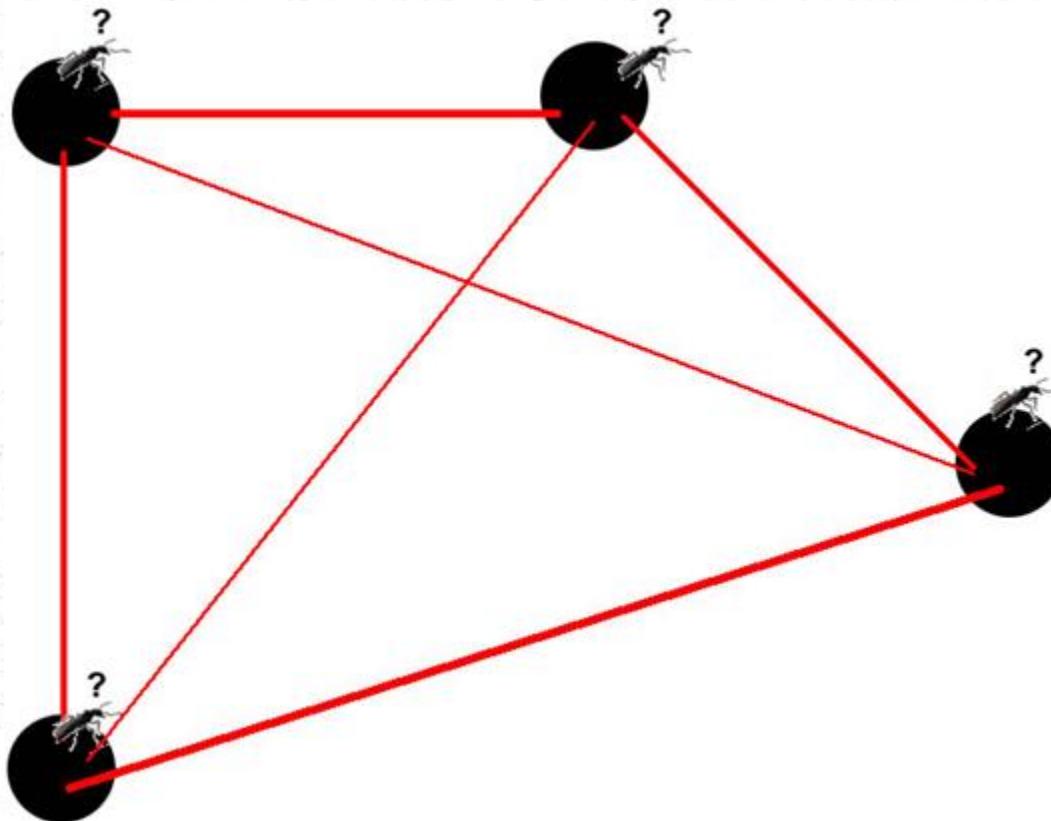
# Otimização por Colônia de Formigas

- Como os caminhos são gerados seguindo uma fórmula *probabilística*, cada formiga pode obter caminhos diferentes das demais;



# Otimização por Colônia de Formigas

- Após a construção de todos os caminhos, a intensidade de feromônio em cada aresta é acrescida *proporcionalmente à qualidade da solução gerada*;



# Otimização por Colônia de Formigas

```
While it < max_it do,  
    for each ant do,  
        build_solution();  
    end for  
    update_pheromone();  
end while
```

Dorigo, M. Optimization, Learning and Natural Algorithms. Politecnico di Milano, Italy, 1992.

# Otimização por Colônia de Formigas

```
While it < max_it do,  
    for each ant do,  
        build_solution();  
    end for  
    update_pheromone();  
end while
```



Dorigo, M. Optimization, Learning and Natural Algorithms. Politecnico di Milano, Italy, 1992.

# Otimização por Colônia de Formigas

## build\_solution()

- Para construir a solução, cada formiga utiliza iterativamente uma *função probabilística* para decidir se incluirá ou não determinada aresta na solução.

$$p_{i,j}^k(t) = \begin{cases} \frac{\tau_{i,j}(t)}{\sum_{j \in J^k} \tau_{i,j}(t)} & \text{se } j \in J^k \\ 0 & \text{c.c.} \end{cases}$$

onde:

- $J^K$  é a lista de vértices ainda não visitados;
- $\tau_{i,j}$  é a quantidade de feromônio na aresta  $(i,j)$ ;
- Se temos como avaliar antecipadamente o impacto que cada aresta terá na qualidade da solução, por que não usar isso? 33

# Otimização por Colônia de Formigas

## build\_solution()

- *Função probabilística* com adição de termo heurístico:

$$p_{i,j}^k(t) = \begin{cases} \frac{\tau_{i,j}^\alpha(t) \cdot \eta_{i,j}^\beta}{\sum_{j \in J^k} \tau_{i,j}^\alpha(t) \cdot \eta_{i,j}^\beta} & \text{se } j \in J^k \\ 0 & \text{c.c.} \end{cases}$$

onde:

- $J^K$  é a lista de vértices ainda não visitados;
- $\tau_{i,j}$  é a quantidade de feromônio na aresta  $(i,j)$ ;
- $\eta_{i,j}$  é a informação de qualidade dessa aresta;
- $\alpha$  e  $\beta$  são parâmetros que definem o grau de importância de  $\tau$  e  $\eta$ , respectivamente.

# Otimização por Colônia de Formigas

```
While it < max_it do,  
    for each ant do,  
        build_solution();  
    end for  
    update_pheromone();  
end while
```



Dorigo, M. Optimization, Learning and Natural Algorithms. Politecnico di Milano, Italy, 1992.

# Otimização por Colônia de Formigas

## update\_pheromone()

- Para atualizar a trilha de feromônio nas arestas, é calculada inicialmente a quantidade a ser depositada em cada uma delas, *proporcional à qualidade das soluções* a que elas pertencem:

$$\Delta\tau_{i,j} = \begin{cases} f(S) & \text{se } (i, j) \in S \\ 0 & \text{c.c.} \end{cases}$$

$$\tau_{i,j}(t+1) = (1 - \rho) \cdot \tau_{i,j}(t) + \rho \cdot \Delta\tau_{ij}$$

onde:

- $\rho$  é a taxa de evaporação do feromônio;
- $\Delta\tau_{i,j}$  é a quantidade de feromônio que será depositada na aresta  $(i,j)$ ;
- $f(S)$  é o custo total da solução “S”

# Otimização por Colônia de Formigas

- Apesar de ter sido originalmente aplicado ao problema do caixeiro viajante, as abordagens baseadas em otimização por colônias de formigas vêm sendo utilizadas com sucesso nas mais diversas aplicações, como:
  - Roteamento em redes de dados;
  - Balanceamento de dados em redes de telecomunicações;
  - Roteamento de veículos;
  - Sequenciamento de tarefas (scheduling);
  - Determinação de redes de distribuição de produtos;
  - Posicionamento de centros de distribuição.

# Otimização por Enxame de Partículas

- Do inglês Particle Swarm Optimization - PSO;
- Busca criar uma **simulação do comportamento social humano**, particularmente a capacidade humana de processar conhecimento;
- Assim como todas as outras abordagens de inteligência de enxame, também está baseada em uma **população de indivíduos capazes de interagir entre si e com o meio ambiente**;
- Comportamentos globais serão, portanto, **resultados emergentes dessas interações**;

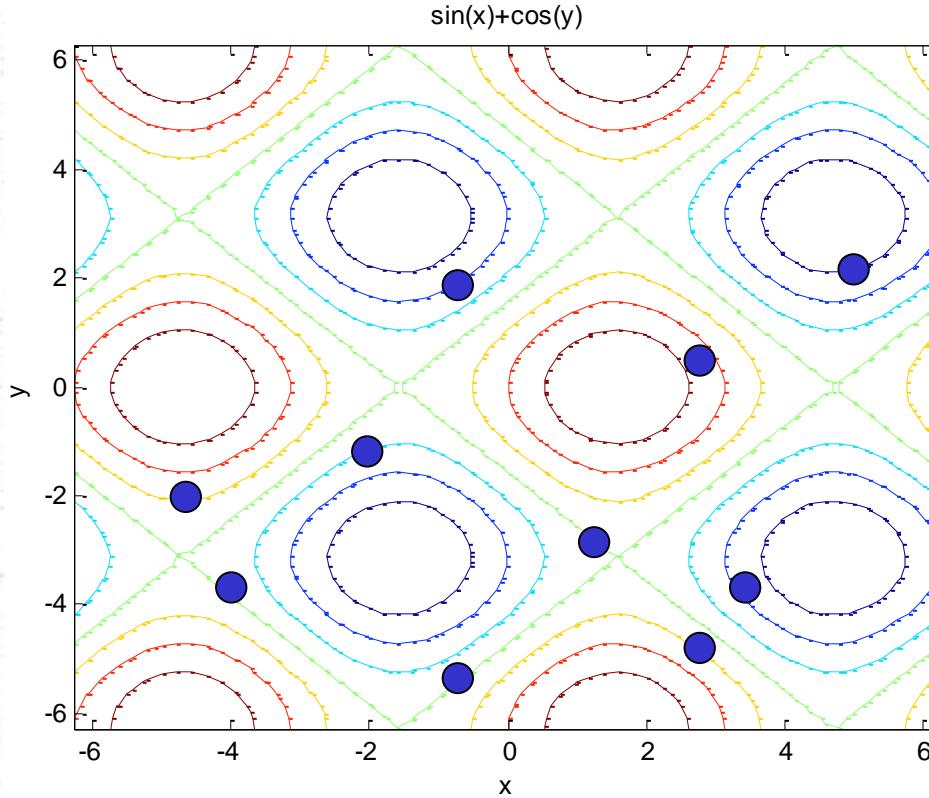
# Otimização por Enxame de Partículas

- Teoria sócio-cognitiva por trás do PSO:
  - Cada indivíduo de uma população possui sua própria experiência e é capaz de avaliar a qualidade desta experiência;
  - Como os indivíduos são sociais, eles também possuem conhecimentos sobre como seus vizinhos se comportaram (desempenharam).
  - Estes dois tipos de informação correspondem à aprendizagem individual (**cognitiva**) e à transmissão cultural (**social**), respectivamente.

# Otimização por Enxame de Partículas

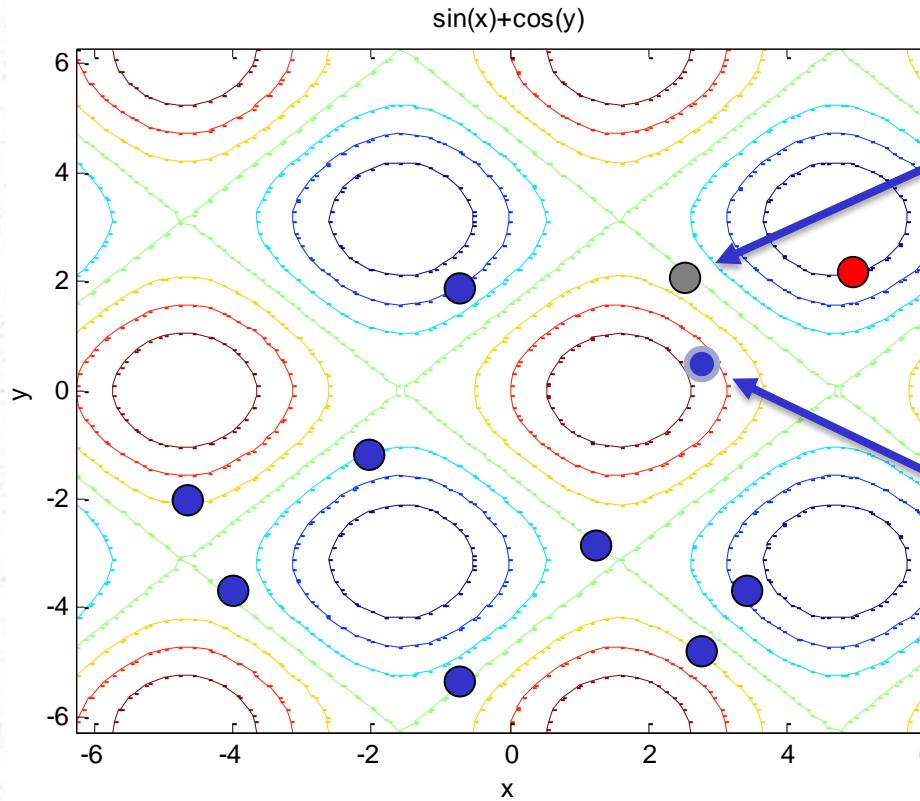
- A probabilidade de um determinado indivíduo tomar uma certa decisão será uma função de seu **desempenho no passado** e do **desempenho de alguns de seus vizinhos**.
- Princípios utilizados para resumir o processo de adaptação cultural:
  - Avalie;
  - Compare;
  - Imitate.

# PSO - Exemplo



- Inicialmente, no algoritmo, diversas partículas são espalhadas aleatoriamente no espaço de busca.

# PSO - Exemplo

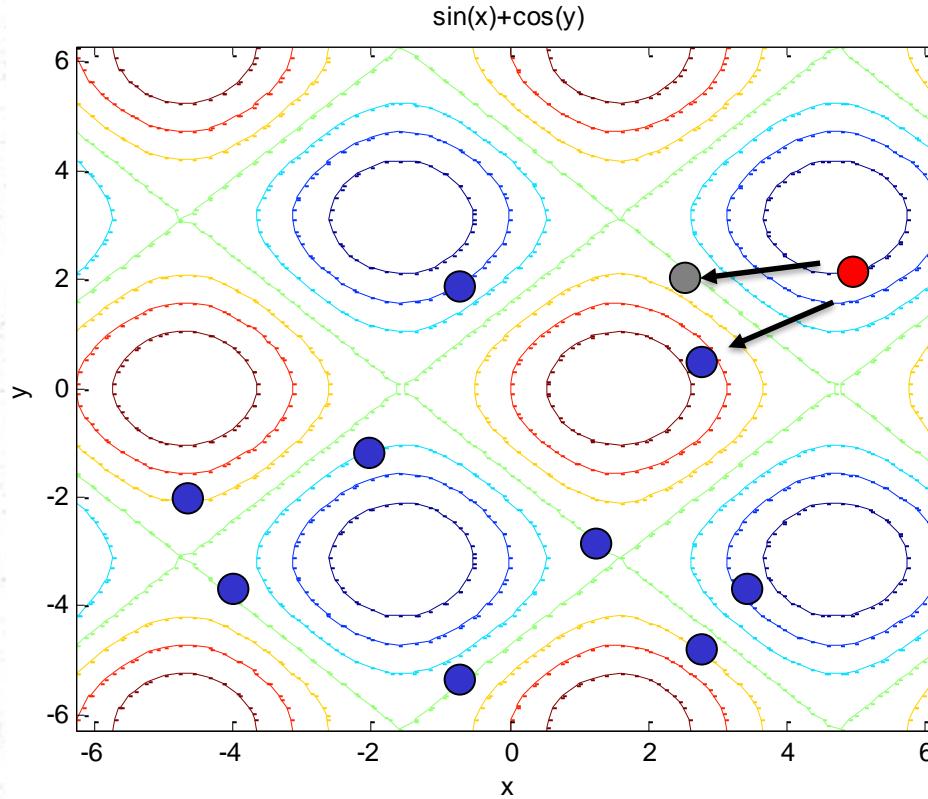


Melhor solução dessa partícula em iterações passadas

Melhor solução na vizinhança

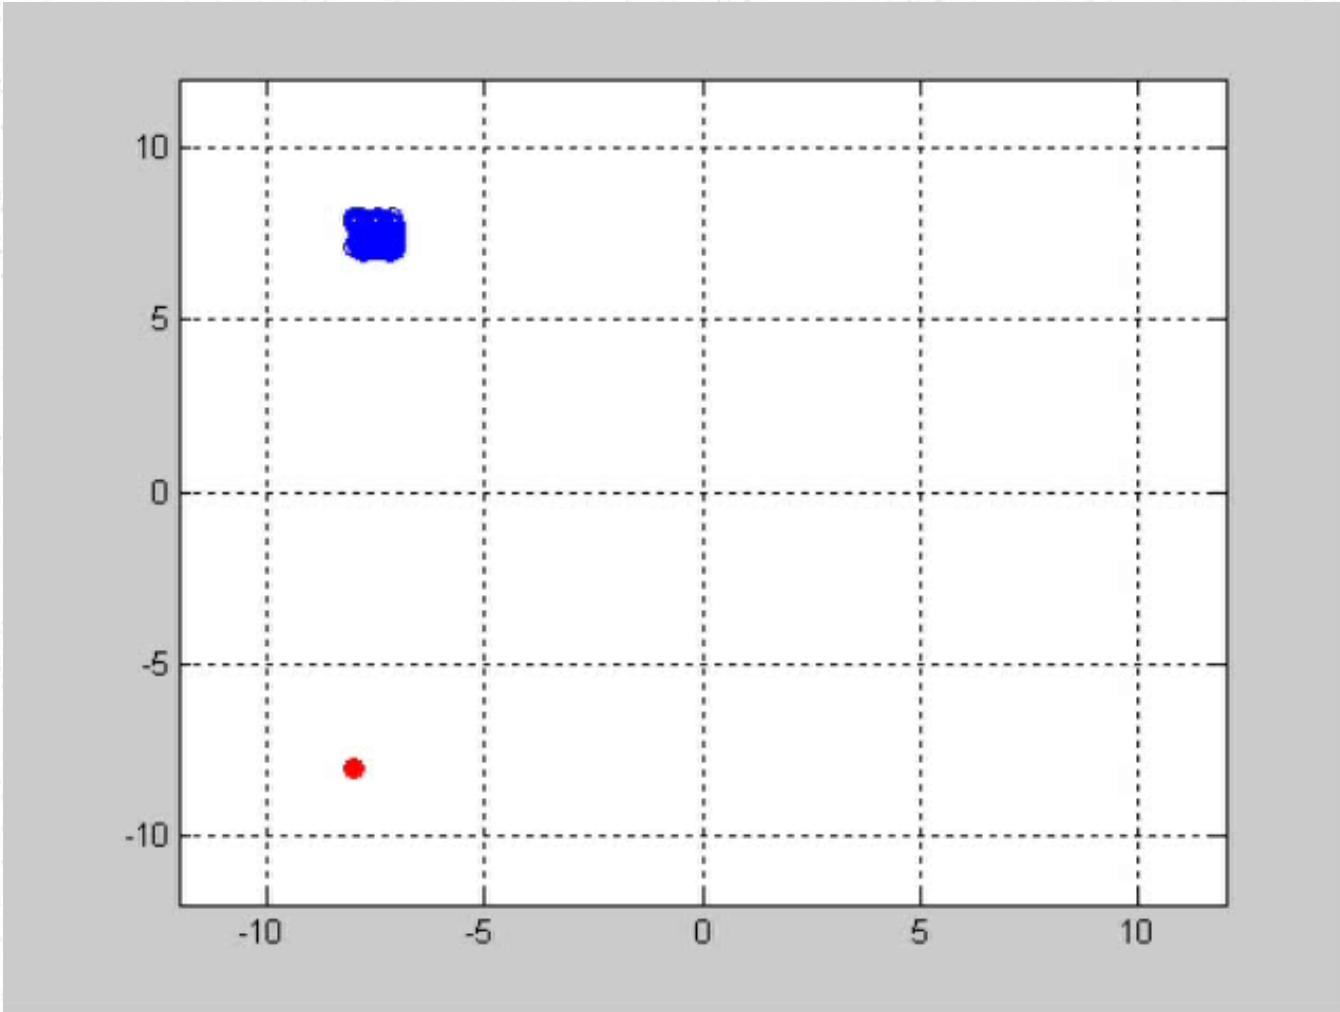
- Iterativamente cada partícula utiliza a informação de sua melhor posição no passado (em cinza) e da melhor posição atual entre seus vizinhos.

# PSO - Exemplo



- E então a partícula se move de forma a se aproximar de sua melhor solução histórica e de seu melhor vizinho.

# PSO - Exemplo



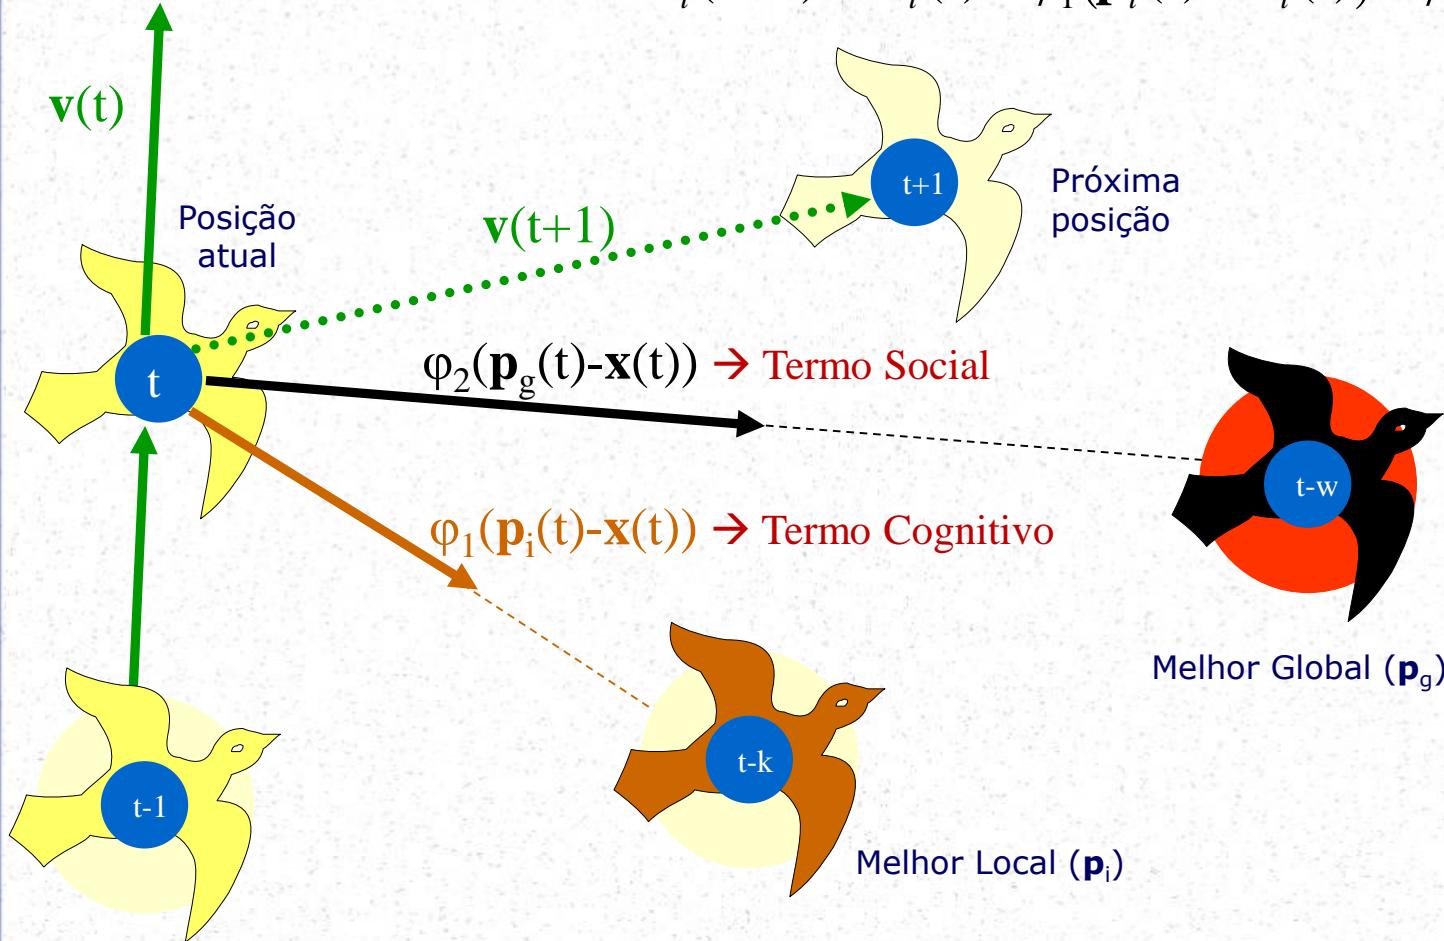
Há um  
vídeo  
associado a  
este slide.

# Otimização por Enxame de Partículas

**Deslocamento de uma partícula:**

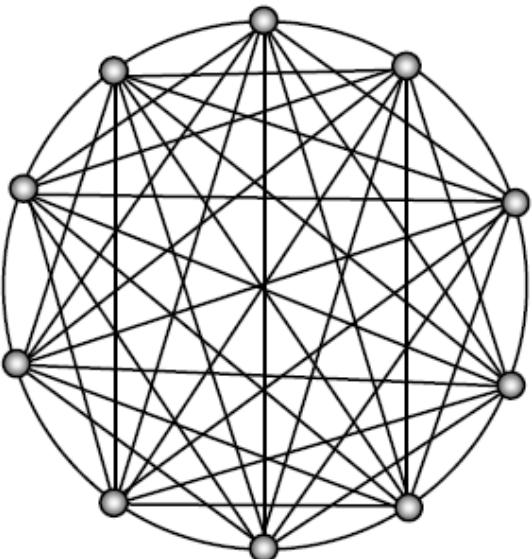
$$\mathbf{x}_i(t+1) = \mathbf{x}_i(t) + \mathbf{v}_i(t+1)$$

$$\mathbf{v}_i(t+1) = \mathbf{v}_i(t) + \varphi_1(\mathbf{p}_i(t) - \mathbf{x}_i(t)) + \varphi_2(\mathbf{p}_g(t) - \mathbf{x}_i(t))$$

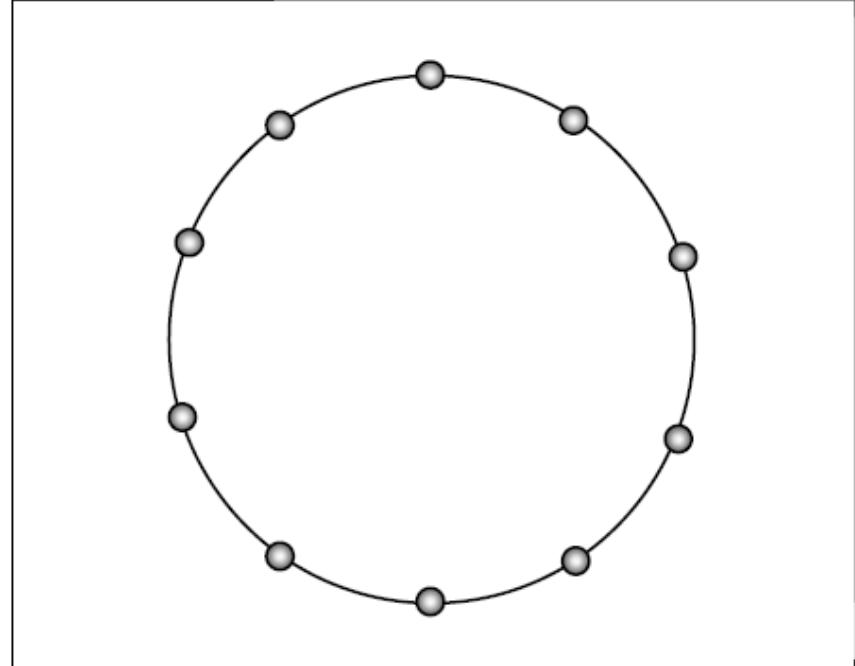


# Otimização por Enxame de Partículas

## Principais tipos de vizinhança de partículas:



**Gbest** – conecta todas as partículas entre si;  
( $G = \text{global}$ );



**Lbest** – vizinhança composta pelas  $k$  partículas mais próximas ( $L = \text{local}$ ); 46

# Otimização por Enxame de Partículas

## Algoritmo PSO Clássico:

- inicializa a população:  $X$ , “melhores Locais”,  $V$
- inicializa outros parâmetros:  $\varphi_1$ ,  $\varphi_2$ ,  $V_{max}$

### WHILE(not parada)

- avalia população  $f(X)$

### FOR(partícula): $i$

- atualiza cada “melhor histórico”
- atualiza “melhor vizinho”
- atualiza  $V_i$
- corrige  $V_i$     **← Limita a velocidade para manter estabilidade**
- calcula nova posição  $X_i$

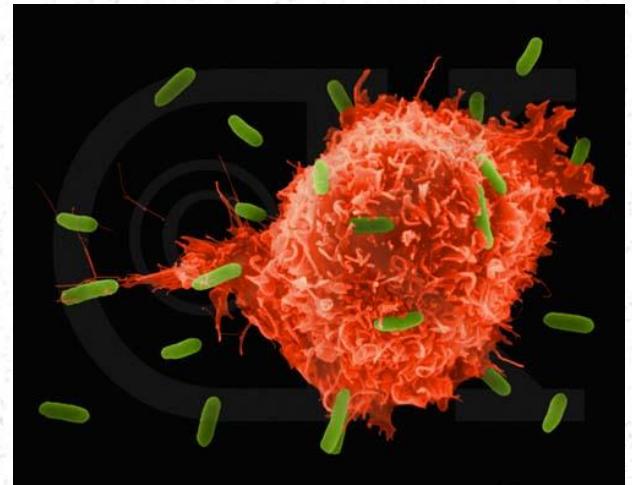


SCIENCEphotOLIBRARY

# SISTEMAS IMUNOLÓGICOS ARTIFICIAIS

# Sistema Imunológico Natural

- O Sistema Imunológico Natural é um dos mais importantes componentes dos organismos superiores;
- Seus mecanismos de reconhecimento e combate a agentes infecciosos externos (*patógenos*) têm o objetivo de manter o organismo saudável;
- Propriedades:
  - Reconhecimento de padrões;
  - Detecção distribuída de anomalias;
  - Tolerância a ruídos;
  - Aprendizagem;
  - Memória.



# Sistema Imunológico Natural

- Sub-divisões do sistema imunológico natural:
  - Sistema Inato: possui componentes capazes de responder a uma ampla gama de agentes invasores, sem a necessidade de uma exposição prévia a eles;
  - Sistema Adaptativo: possui componentes que são estimulados em resposta a infecções específicas → imunidade contra re-infecções.
- Juntos, os sistemas imunológicos inato e adaptativo contribuem para um mecanismo de defesa extremamente **eficiente**, que opera em **paralelo**, recorrendo a uma diversidade de agentes e componentes **distribuídos espacialmente** e **operando em rede**.

# Sistema Imunológico Natural

## Sistema Imunológico Inato

- Primeira linha de defesa do organismo;
- Pronto para o combate;
- Defende o organismo de forma **não específica**, ou seja, reage de maneira semelhante para diferentes patógenos.
- Principais armas:
  - Pele;
  - Barreiras Bioquímicas – saliva, lágrima, ácidos gastrointestinais;
  - Células (macrófagos, por exemplo).
- O sistema inato não consegue combater alguns patógenos.

# Sistema Imunológico Natural

## Sistema Imunológico Adaptativo

- Responde especificamente a alguns patógenos → maior eficiência;
- Uma vez ativado para um determinado tipo de patógeno, mantém uma imunidade duradoura → memória;
- Principais armas:
  - Células T;
  - Células B;
  - Anticorpos;

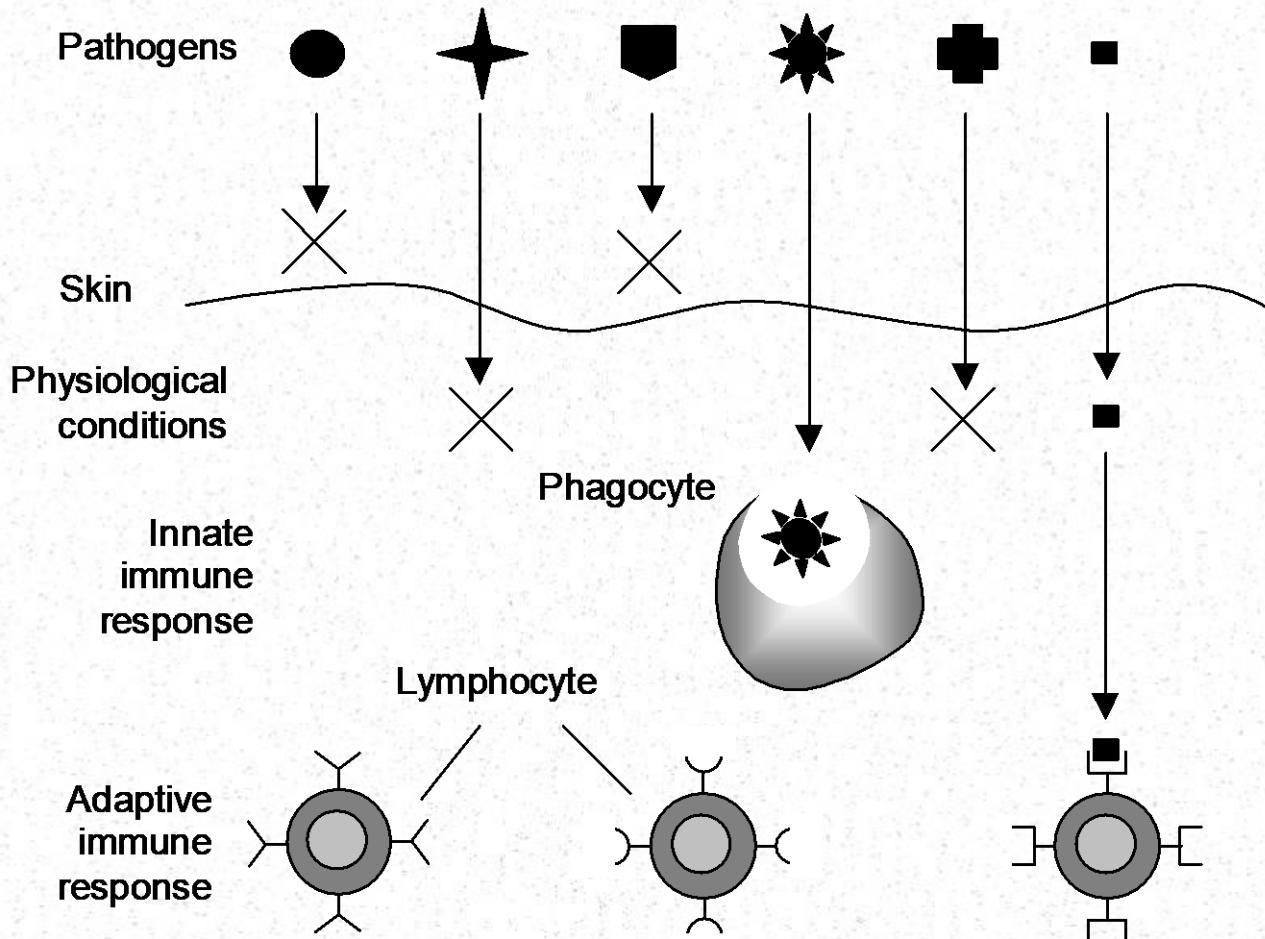
# Sistema Imunológico Natural

## Elementos do SI – Células Mediadoras

	<b>Progenitor da Célula Mediadora</b>	<b>Célula Mediadora</b>	<b>Imunidade</b>	
Célula-tronco hematopoietica	Progenitor Mielóide	Macrófago	Inata	
		Célula Dendrítica		
		Mastócito		
		Granulócito		
		Neutrófilo		
		Eosinófilo		
		Basófilo		
Célula-tronco hematopoietica	Progenitor Linfóide Comum	Célula T	Adaptativa	
		Célula B		

# Sistema Imunológico Natural

## SI – Sistema Multicamadas



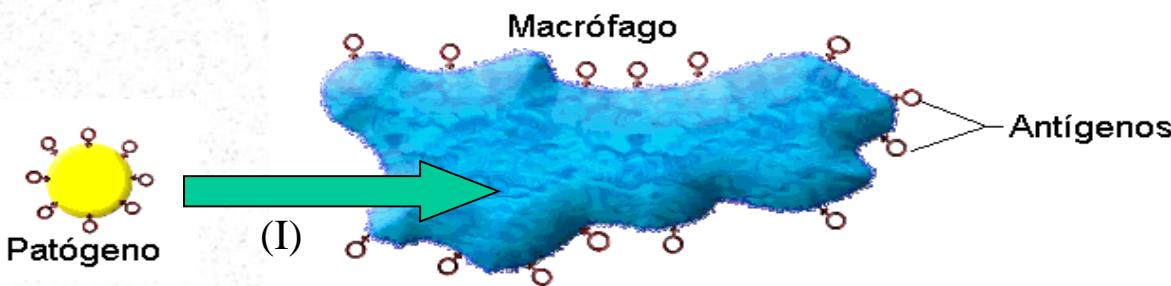
# Sistema Imunológico Natural

## Resposta Imunológica Adaptativa



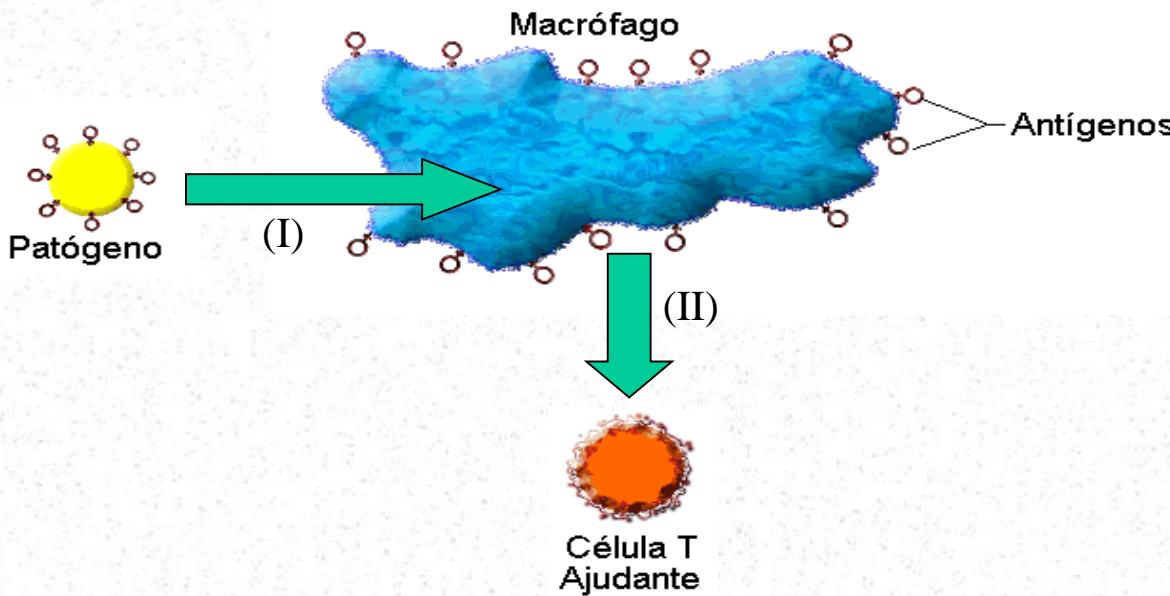
# Sistema Imunológico Natural

## Resposta Imunológica Adaptativa



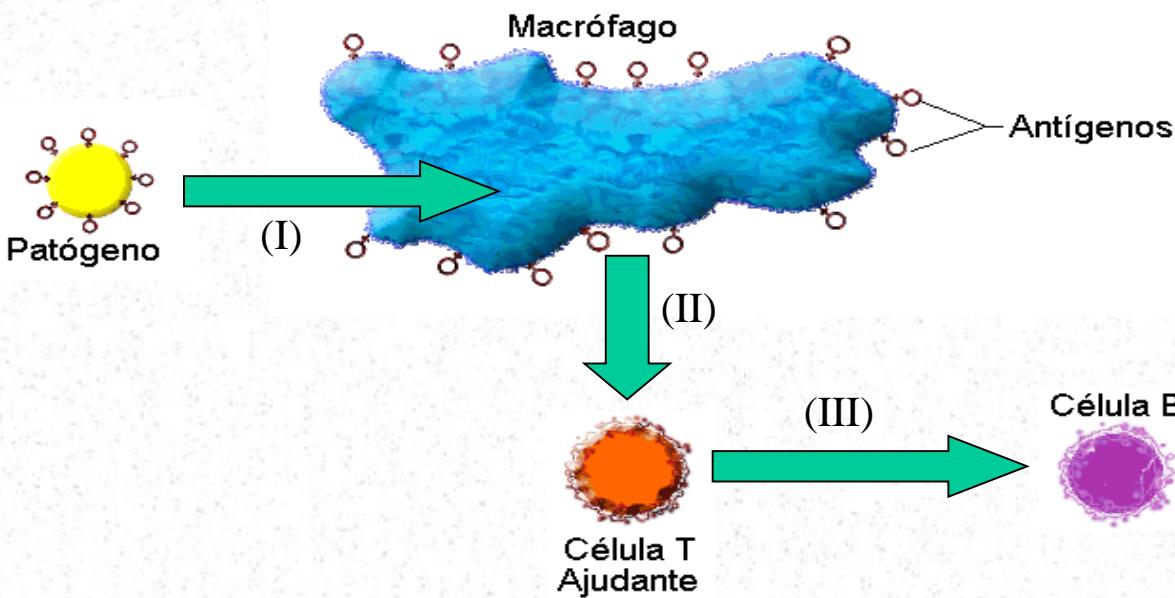
# Sistema Imunológico Natural

## Resposta Imunológica Adaptativa



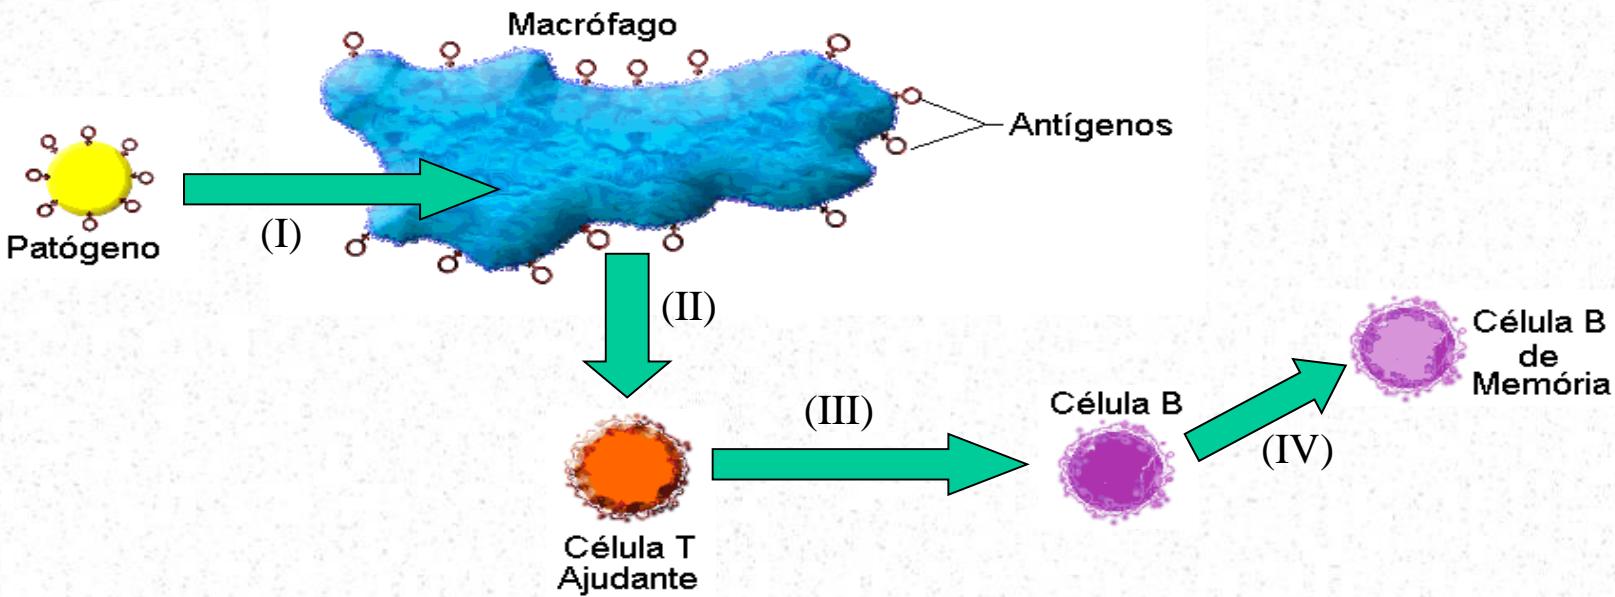
# Sistema Imunológico Natural

## Resposta Imunológica Adaptativa



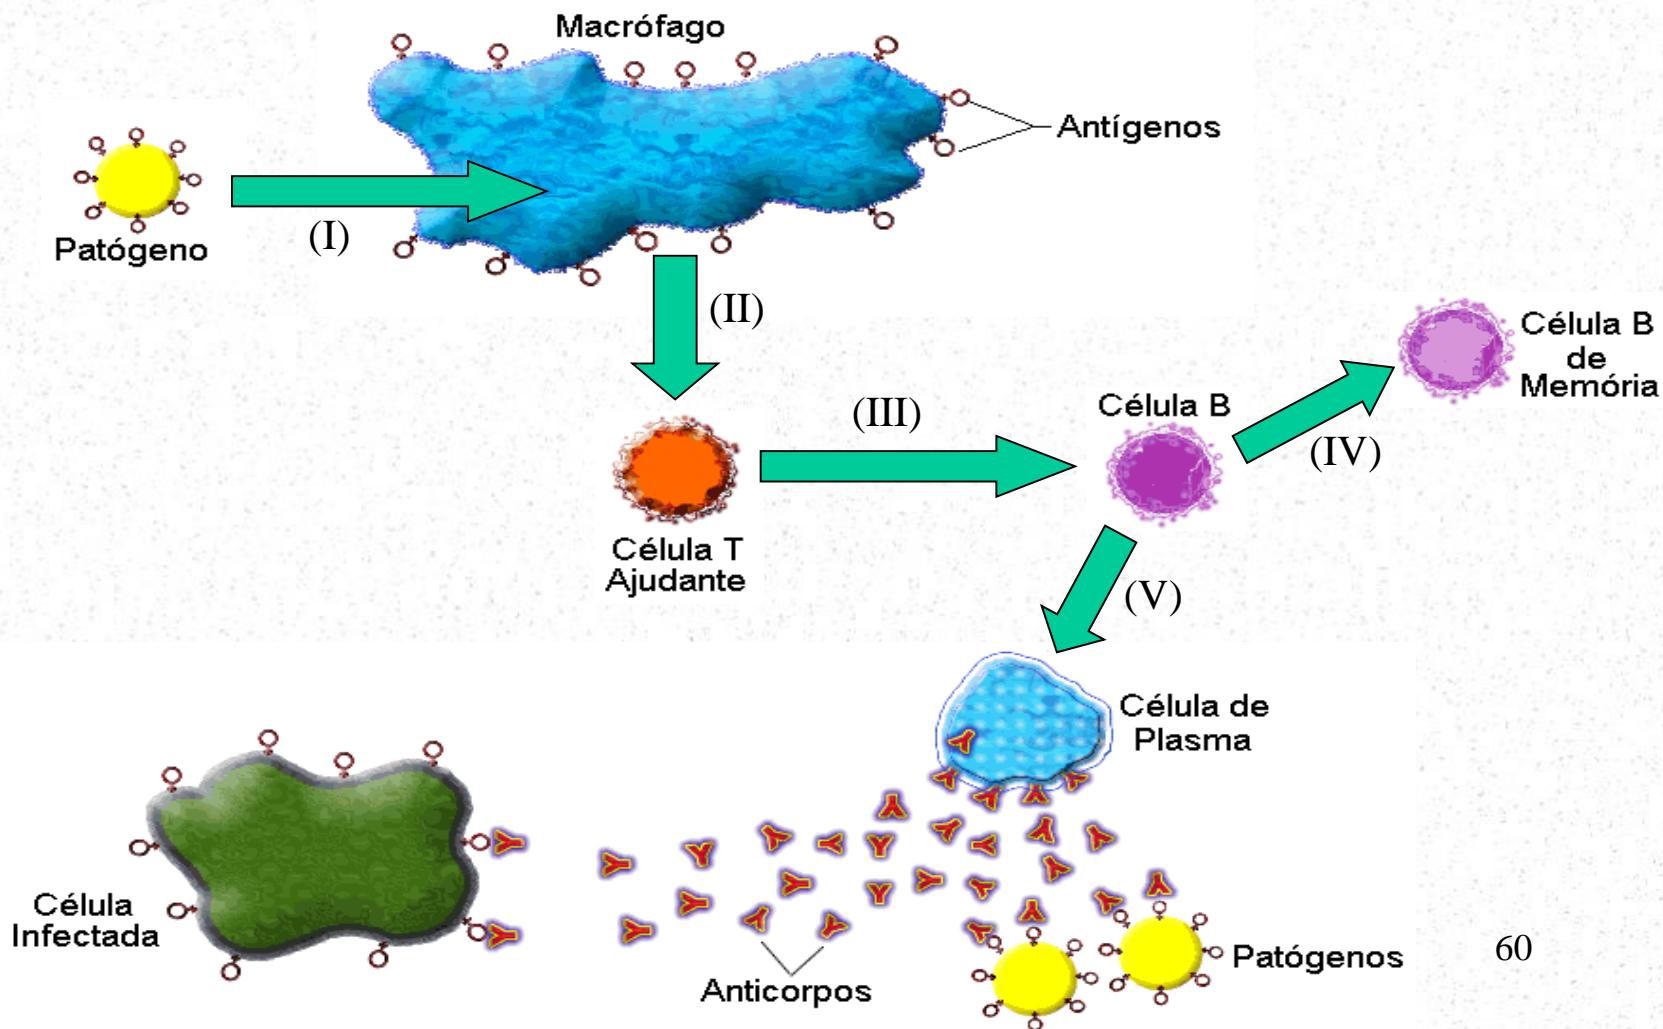
# Sistema Imunológico Natural

## Resposta Imunológica Adaptativa



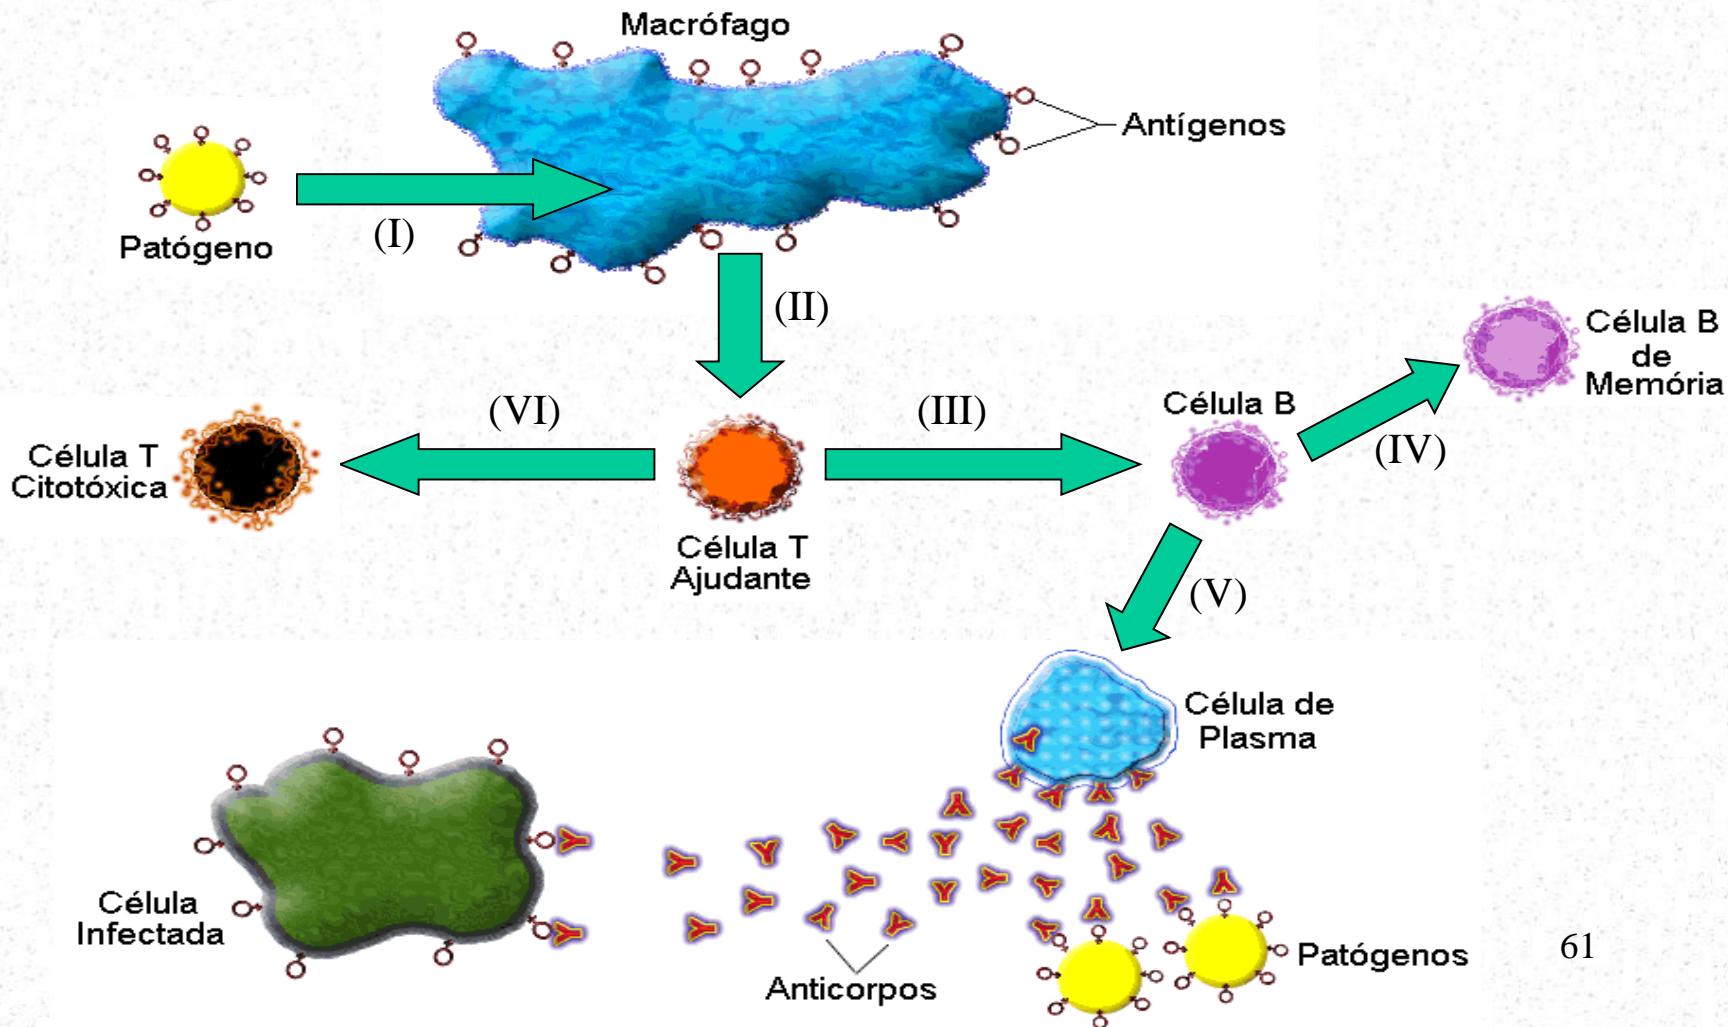
# Sistema Imunológico Natural

## Resposta Imunológica Adaptativa



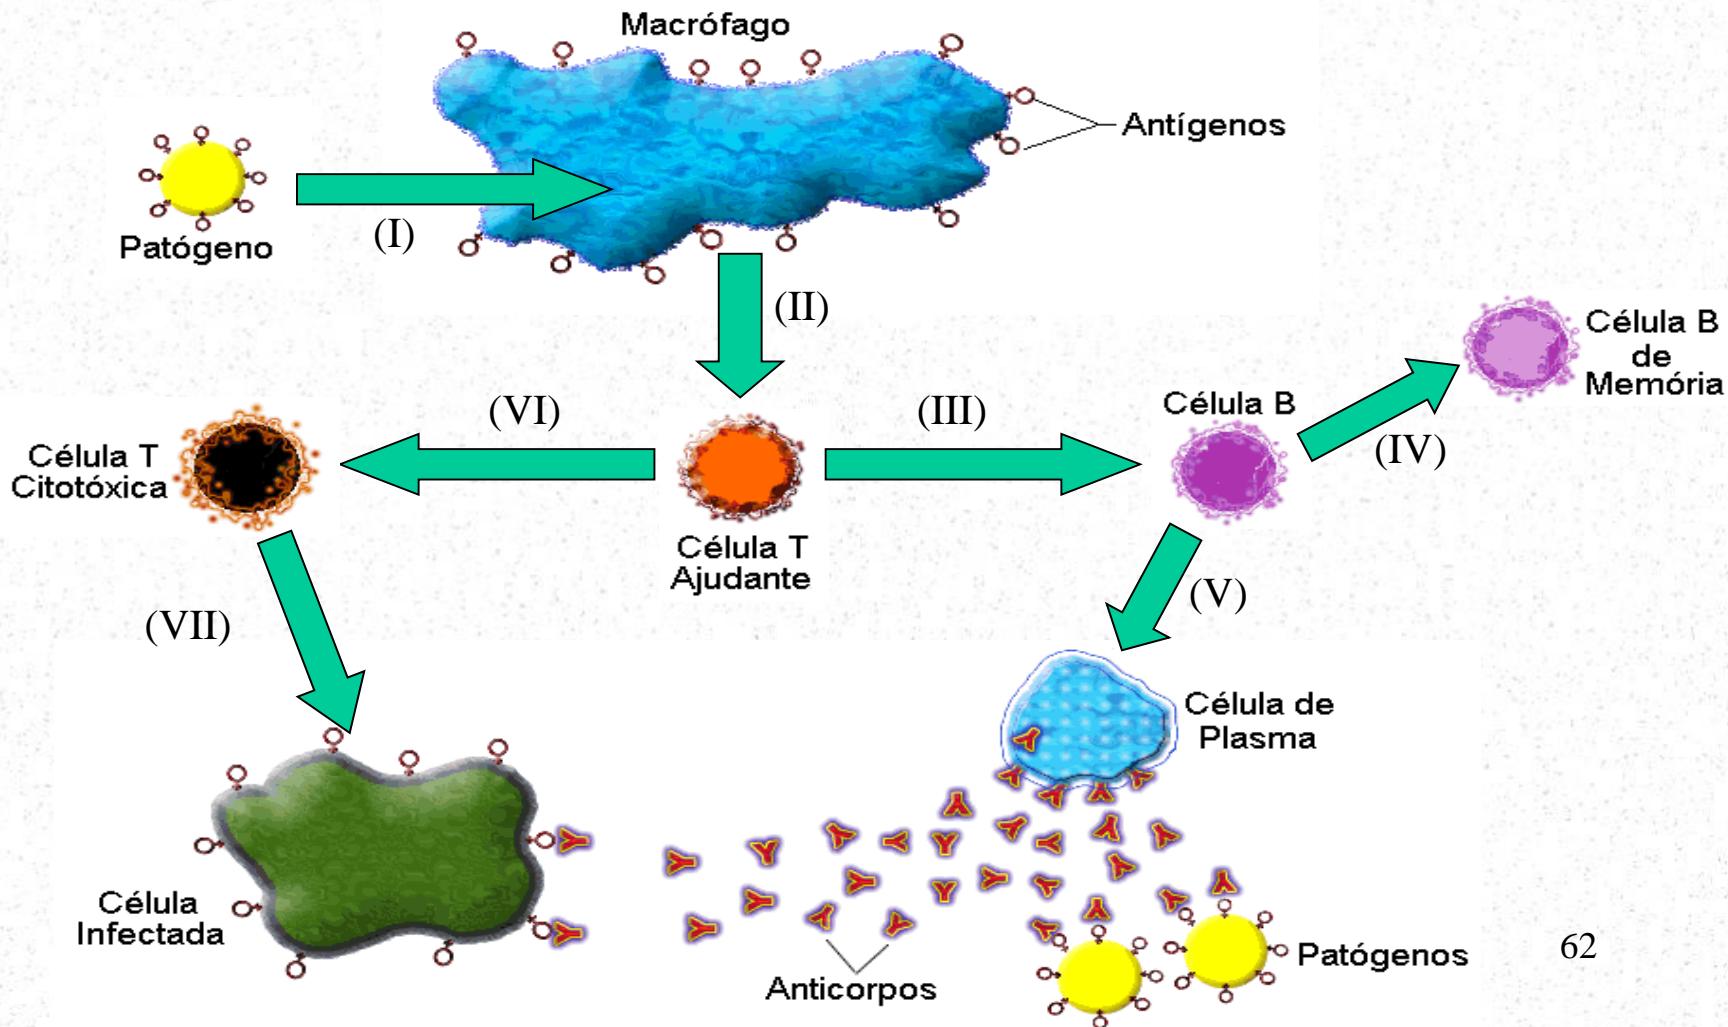
# Sistema Imunológico Natural

## Resposta Imunológica Adaptativa

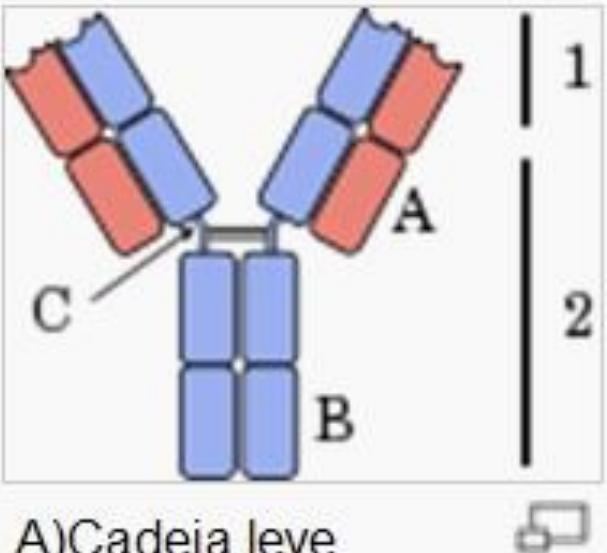


# Sistema Imunológico Natural

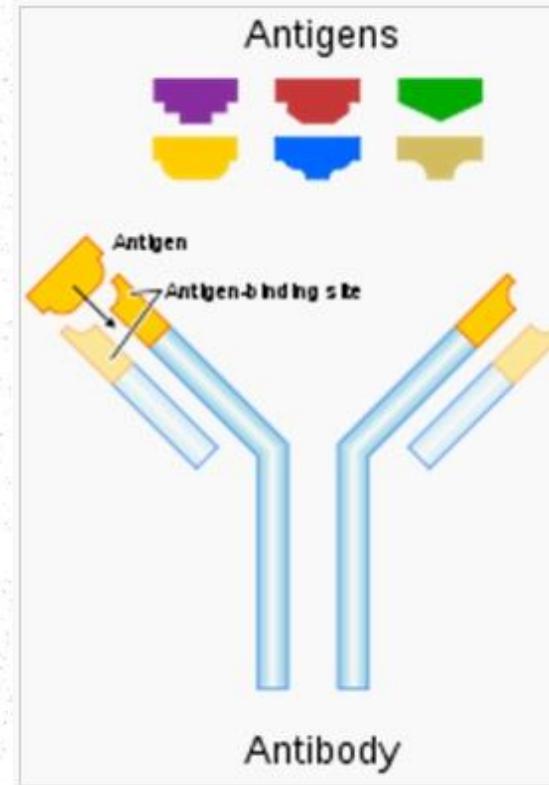
## Resposta Imunológica Adaptativa



# Estrutura e operação do anticorpo

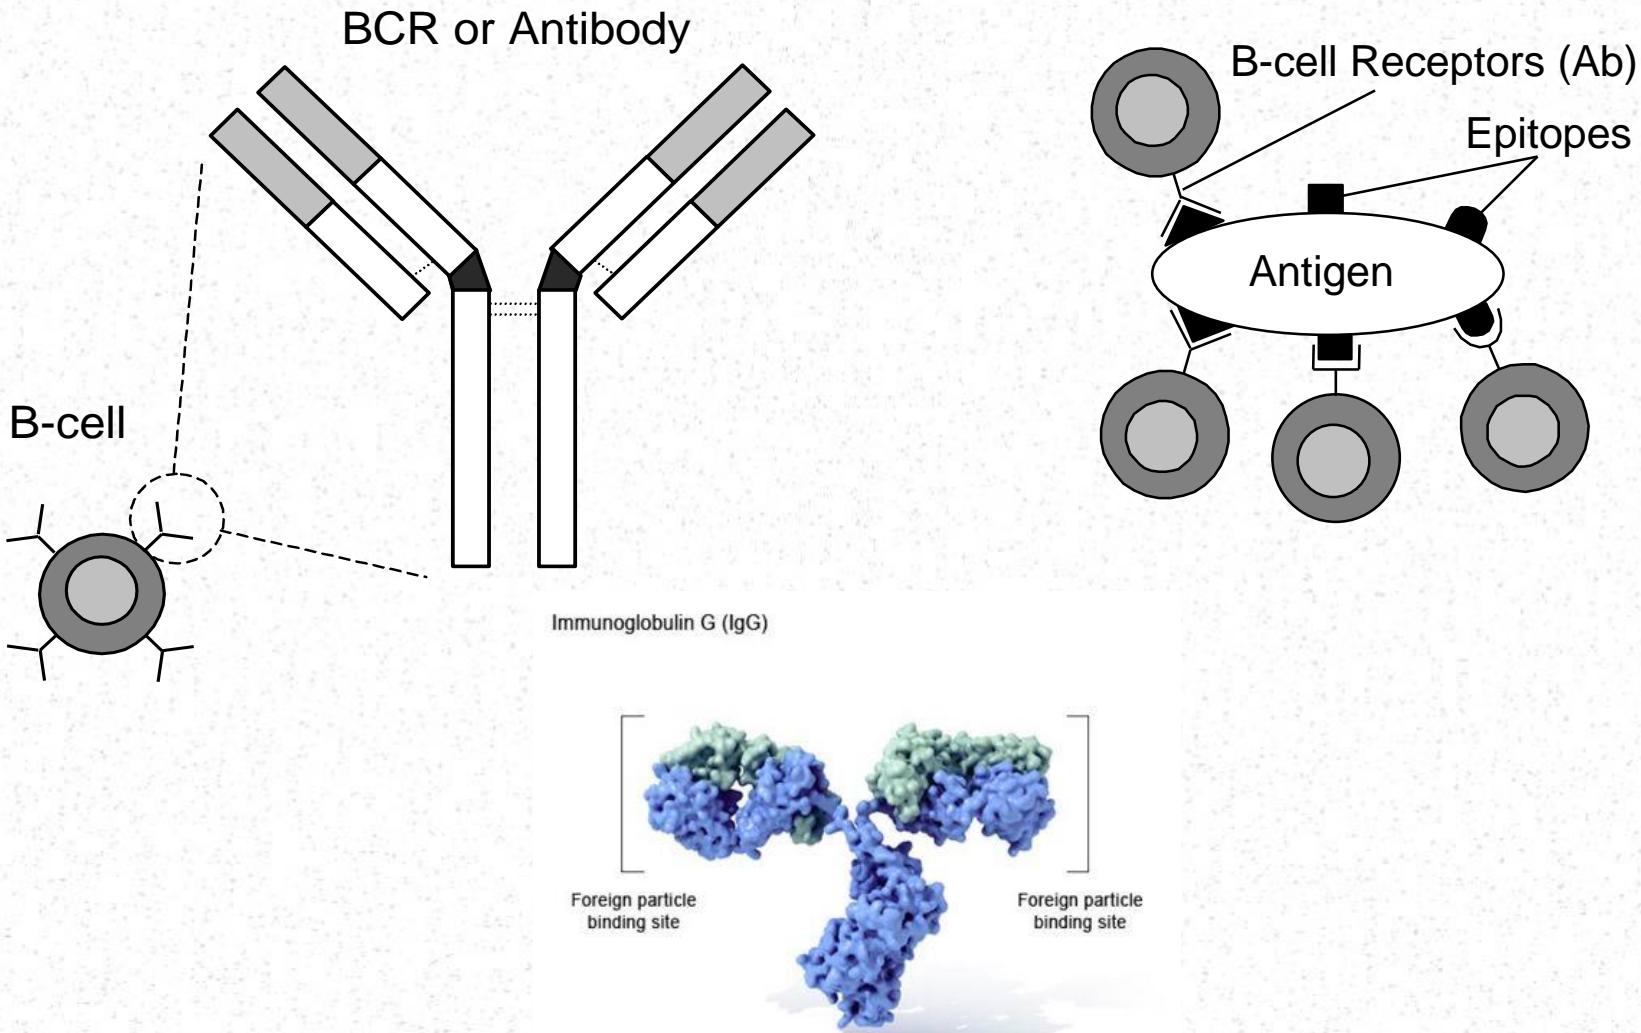


- A) Cadeia leve
- B) Cadeia pesada
- C) Pontes dissulfeto
- 1) Região variável
- 2) Região Constante



Visão pictórica da ligação de um anticorpo a um antígeno.

# Estrutura e operação do anticorpo





# Sistema Imunológico Natural

## Resposta Adaptativa: Princípio da Seleção Clonal

- Quando um anticorpo possui alta afinidade a um dado antígeno, as células B que o produzem se multiplicam com maior velocidade através de *clonagem*;
- Durante esse processo, os novos clones gerados sofrem *hipermutação*, com taxas de variabilidade inversamente proporcionais à sua afinidade ao antígeno em questão;
- Dentre as novas células geradas, as que possuem maior afinidade com o antígeno são *selecionadas* e as demais *suprimidas*;
- Este processo de expansão clonal, hipermutação e seleção das células com receptores mais adaptados é denominado *Seleção Clonal* [Burnet, 1959].

# Sistema Imunológico Natural

## Resposta Adaptativa: Teoria da Rede Imunológica

- A *Teoria da Rede Imunológica* [Jerne, 1974] coloca que os anticorpos presentes no organismo são capazes de reconhecer não só抗ígenos mas também outros anticorpos;
- Dessa forma, o sistema imunológico pode ser visto como uma **enorme e complexa rede**, onde cada componente reconhece e é reconhecido por outros elementos, e interfere e sofre interferência desses outros elementos;
- Esta relação entre componentes faz com que a rede imunológica permaneça em um **estado de equilíbrio dinâmico** em que alguns elementos sofrem redução de concentração enquanto outros têm sua concentração aumentada;
- Dessa forma, as **respostas imunológicas surgem a partir de alterações neste equilíbrio dinâmico.**



# Sistemas Imunológicos Artificiais (SIA)

“Sistemas Imunológicos Artificiais são sistemas adaptativos, inspirados na imunologia teórica e em funções, princípios e modelos imunológicos e que são aplicados na resolução de problemas.”

[de Castro & Timmis, 2002]

[de Castro & Timmis, 2002] de Castro, L. N. & Timmis, J. (2002), Artificial Immune Systems: A New Computational Intelligence Approach, Springer-Verlag.

# SIA – Escopo de Aplicações

- Robótica:
  - Navegação autônoma;
  - Emergência de comportamento coletivo.
- Controle:
  - Identificação, controle adaptativo.
- Otimização:
  - Restrita, multimodal e combinatória;
  - Dinâmica.
- Análise multivariada de dados:
  - Agrupamento de dados;
  - Filtragem e sumarização;
  - Estimação de densidades.

# SIA – Escopo de Aplicações

- Detecção de Anomalias:
  - Segurança computacional;
  - Seleção negativa;
  - Detecção e eliminação de vírus computacionais;
  - Inspeção de imagens;
  - Séries temporais.
- Abordagens Baseadas em Agentes:
  - Segurança de redes de computadores;
  - Detecção e eliminação de vírus;
  - Prédios inteligentes.

# Projetando um SIA

## Questões a serem respondidas

- Quais metáforas imunológicas utilizar?
- Como simular a Seleção Clonal?
- Como simular a Teoria da Rede?

# Projetando um SIA

## Sistema Imunológico Básico

- Trabalha com uma população de soluções candidatas → **anticorpos**;
- Dados do problema → **antígenos**;
- Aumenta a concentração das melhores soluções;
- Aplica mutação nos indivíduos da população;
- Soluções similares são eliminadas da população.

# Projetando um SIA

## Sistema Imunológico Básico

- Trabalha com uma população de soluções candidatas → **anticorpos**;
- Dados do problema → **antígenos**;
- Aumenta a concentração das melhores soluções;
- Aplica mutação nos indivíduos da população;
- Soluções similares são eliminadas da população.

→ **Teoria da Rede**

**Seleção Clonal** ←

# Projetando um SIA

## Representação

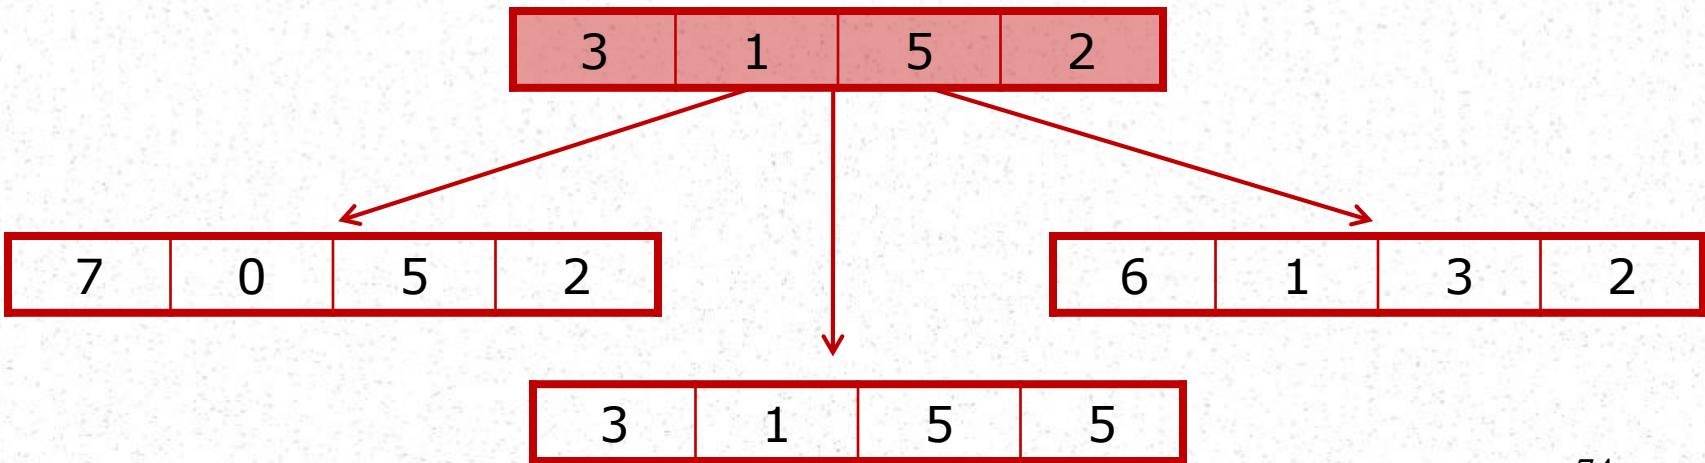
- Geralmente, as soluções candidatas (anticorpos na população) são codificadas como vetores;
- O tipo dos valores em cada posição destes vetores depende da aplicação:
  - Números Inteiros;
  - Números Reais;
  - Valores Binários...



# Projetando um SIA

## Reproduzindo a Seleção Clonal

- Melhores soluções são clonadas;
- Os clones gerados sofrem *hipermutação* com taxa de variabilidade inversamente proporcional à qualidade do indivíduo que os gerou.



# Projetando um SIA

## Reproduzindo a Teoria da Rede

- As soluções candidatas na população são comparadas entre si;
- Soluções que são muito similares são eliminadas → entre duas soluções candidatas similares, a pior é eliminada.

3	1	5	2
---	---	---	---

3	1	5	2
---	---	---	---

3	1	4	2
---	---	---	---

2	1	5	2
---	---	---	---

# Projetando um SIA

- Estes dois princípios imunológicos (Seleção Clonal e Teoria da Rede) fazem com que os SIAs apresentem algumas características interessantes:
  - São inherentemente capazes de **manter a diversidade** da população;
  - O **tamanho da população** a cada geração é **automaticamente definido** de acordo com a demanda da aplicação;
  - Soluções ótimas locais tendem a ser simultaneamente **preservadas** quando localizadas.
- Estas características fazem com que os SIAs possuam mecanismos eficientes de exploração do espaço de busca.

# Algoritmos Imuno-Inspirados

## CLONALG (Princípio da Seleção Clonal)

- Baseado no princípio da Seleção Clonal;
- Aplicação:
  - Agrupamento de Dados (ou *clustering*);
  - Otimização Contínua.

de Castro , L. N. & Von Zuben, F. J., *Learning and Optimization Using the Clonal Selection Principle* , IEEE Transactions on Evolutionary Computation, Special Issue on Artificial Immune Systems, 6 (3), pp. 239-251, 2002.

# Algoritmos Imuno-Inspirados

## CLONALG (Princípio da Seleção Clonal)

- initialize aleatoriamente a população;

**WHILE** (*não for condição de parada*)

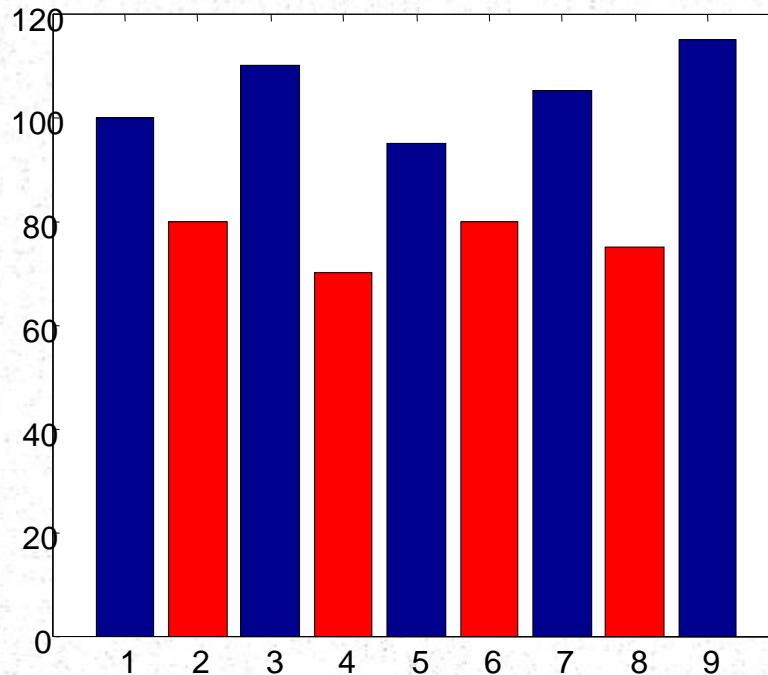
**FOR** (*antígeno i*)

- avalie cada anticorpo na população para *i*;
- selecione parte dos melhores anticorpos para clonagem → quanto melhor o anticorpo, maior o número de clones;
- aplique mutação nos clones → variabilidade inversamente proporcional à qualidade do clone;
- adicione os novos anticorpos à população original e selecione os melhores;
- substitua uma parte dos piores indivíduos por novos indivíduos aleatoriamente gerados;

# Algoritmos Imuno-Inspirados

## CLONALG (Princípio da Seleção Clonal)

- Aspecto Distinto: a população do algoritmo apresenta uma dinâmica de expansão e contração ao longo das iterações:



# Algoritmos Imuno-Inspirados

## aiNet (CLONALG + Teoria da Rede)

- *Artificial Immune Network;*
- Pode ser vista como uma extensão do CLONALG, com a adição de aspectos da teoria da rede;
- Existe uma etapa de comparação entre os anticorpos e supressão;
- Aplicação:
  - **Agrupamento de Dados;**

de Castro, L.N., Von Zuben, F.J. aiNet: An Artificial Immune Network for Data Analysis. *in* Abbass, H.A., Sarker, R.A. & Newton, C.S. (eds.) *Data Mining: A Heuristic Approach*, Idea Group Publishing, pp. 231-259, 2002.

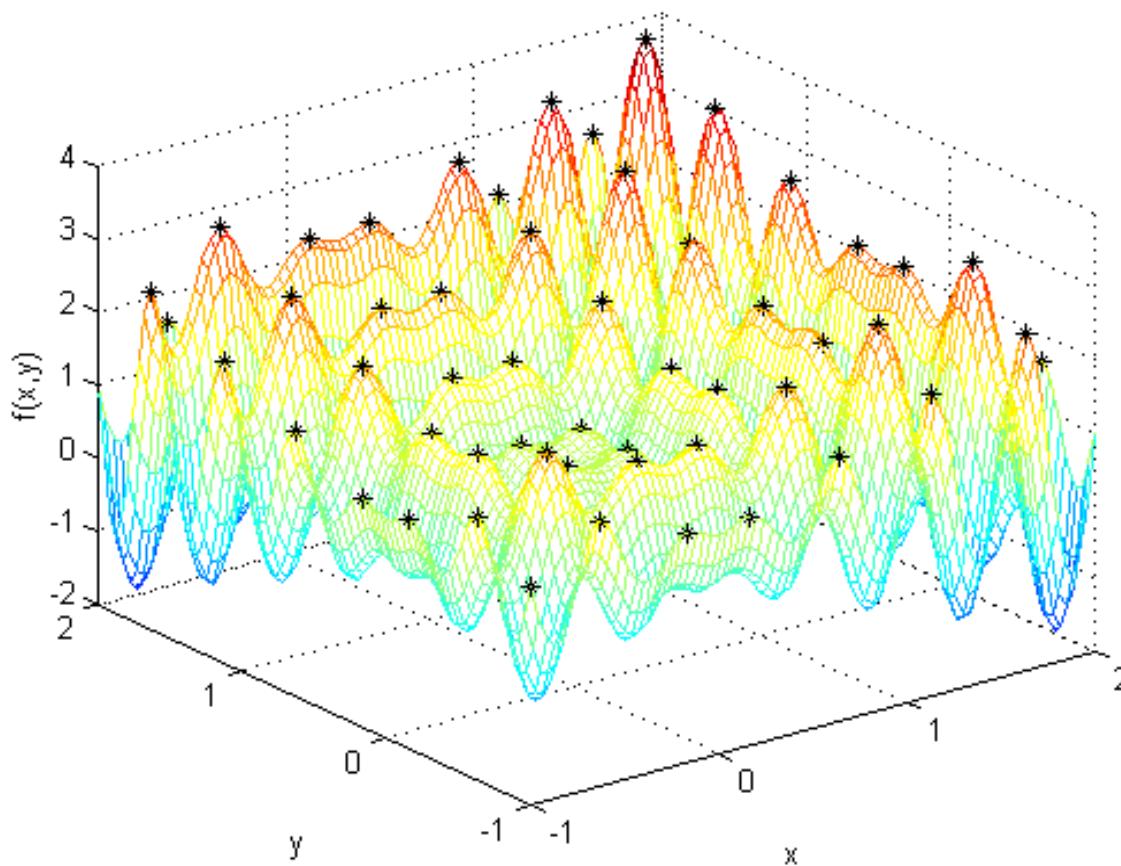
# Algoritmos Imuno-Inspirados

## opt-aiNet

- *Artificial Immune Network for Optimization;*
- Extensão da aiNet para a solução de problemas de otimização multimodal em espaços contínuos;

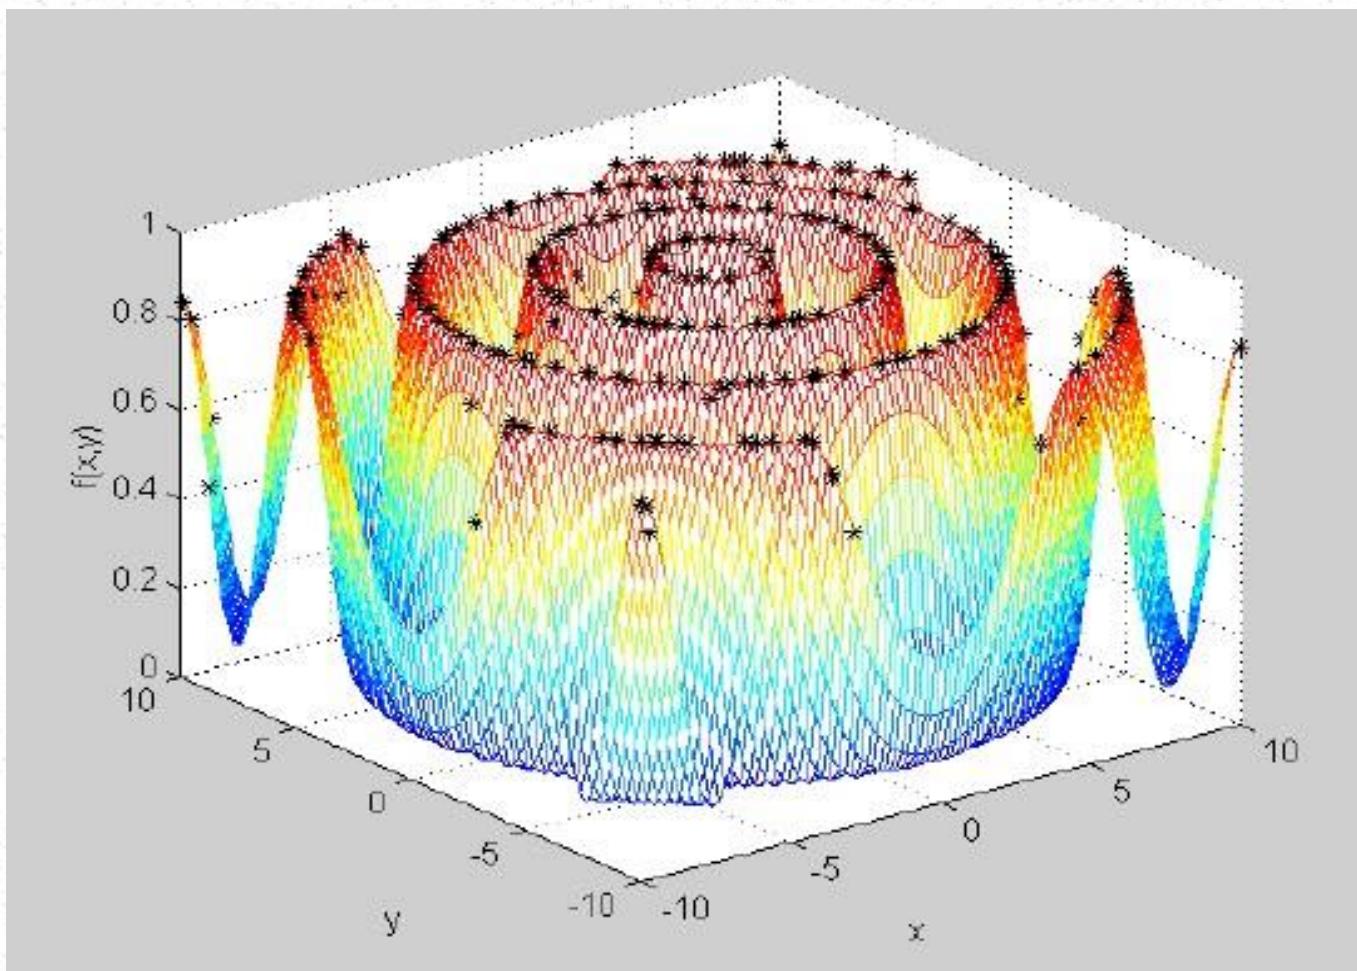
de Castro, L. N. and Timmis, J. *An Artificial Immune Network for Multimodal Function Optimization*. Proceedings of the IEEE Congress on Evolutionary Computation (CEC'02), Vol. 1, pp. 699-674, May, Hawaii, 2002.

# opt-aiNet



Há um  
vídeo  
associado a  
este slide.

# opt-aiNet



# Algoritmos Imuno-Inspirados

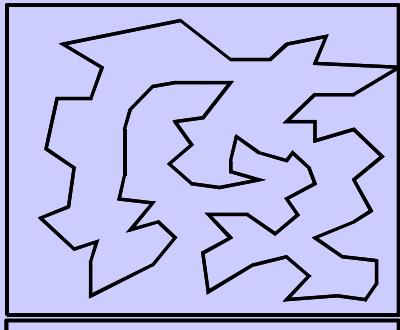
## copt-aiNet

- *Artificial Immune Network for Combinatorial Optimization;*
- Extensão da aiNet para a solução de problemas de otimização multimodal em espaços discretos;

Gomes, L.C.T., de Sousa, J.S., Bezerra, G.B., de Castro, L.N., Von Zuben, F.J. Copt-aiNet and the Gene Ordering Problem. Proceedings of the Second Brazilian Workshop on Bioinformatics (WOB'2003), pp. 28-37, 2003.

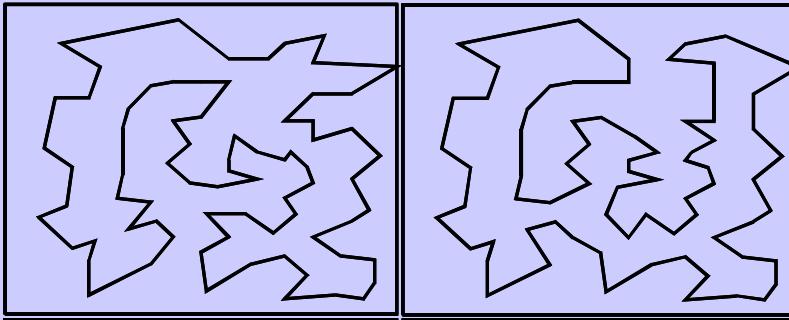
# copt-aiNet – Caixeiro Viajante

TSP: 76 cidades



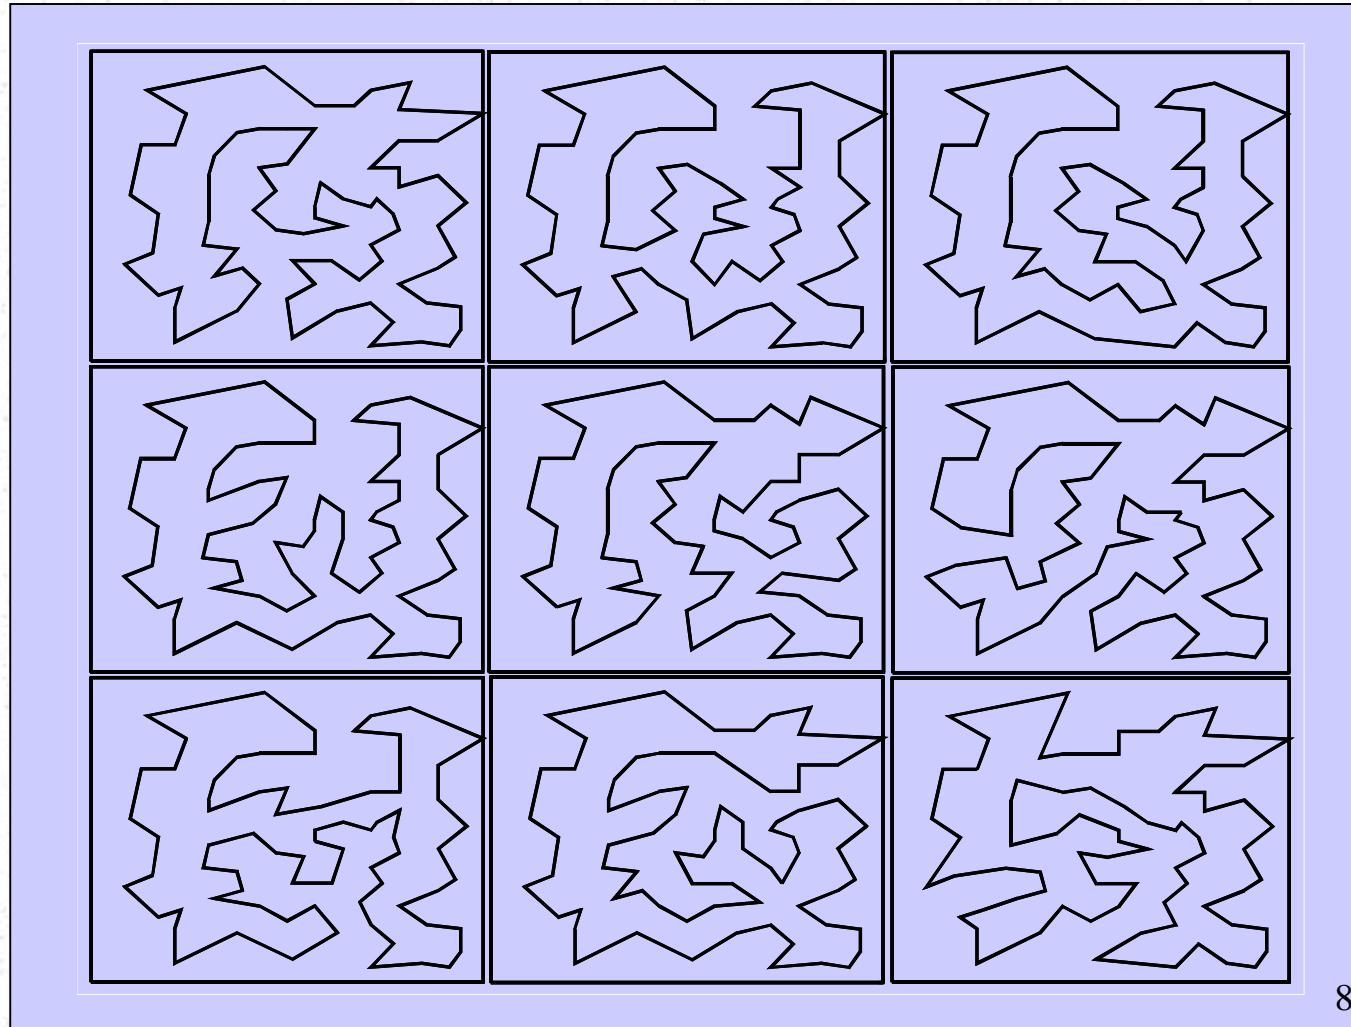
# copt-aiNet – Caixeiro Viajante

TSP: 76 cidades



# copt-aiNet – Caixeiro Viajante

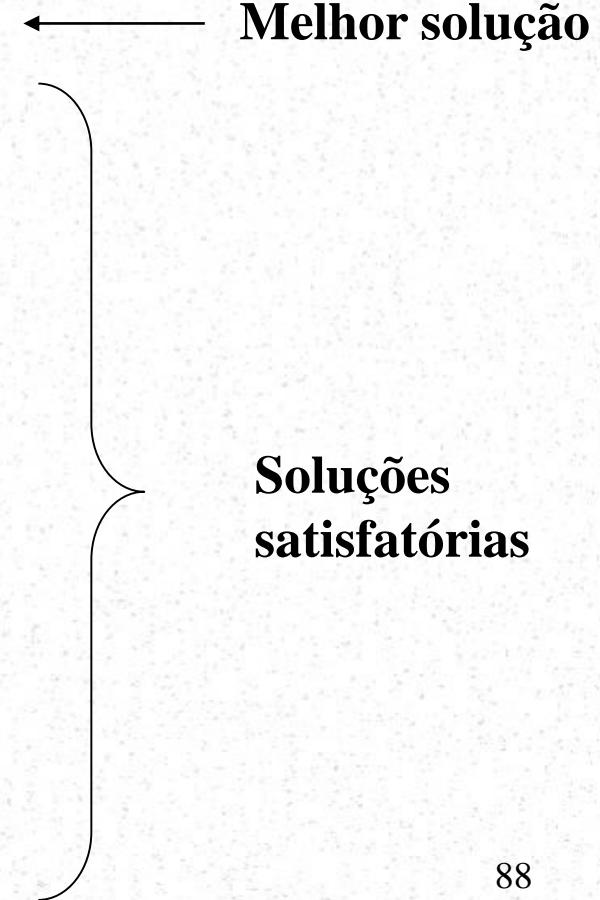
TSP: 76 cidades



# copt-aiNet – Caixeiro Viajante

TSP: 76 cidades

Solução	Custo
1	<b>538</b>
2	<b>541</b>
3	<b>542</b>
4	<b>543</b>
5	<b>544</b>
6	<b>546</b>
7	<b>548</b>
8	<b>552</b>
9	<b>553</b>





# copt-aiNet – Caixeiro Viajante

TSP: 76 cidades

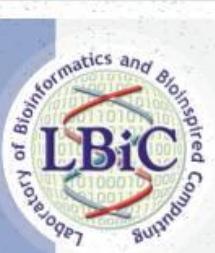
Solution	0	1	2	3	4	5	6	7	8	Cost
0	0	17	19	19	14	13	23	15	18	538
1	17	0	14	16	18	17	17	21	27	541
2	19	14	0	17	22	24	17	19	24	542
3	19	16	17	0	21	22	12	13	25	543
4	14	18	22	21	0	13	21	18	24	544
5	13	17	24	22	13	0	27	23	22	546
6	23	17	17	12	21	27	0	19	27	548
7	15	21	19	13	18	23	19	0	24	552
8	18	27	24	25	24	22	27	24	0	553
Cost of the best known solution: 538										

# Algoritmos Imuno-Inspirados

## dopt-aiNet

- *Artificial Immune Network for Dynamic Optimization;*
- Extensão da aiNet para a solução de problemas de otimização dinâmica em espaços contínuos;
- Utiliza basicamente o mesmo mecanismo de busca da opt-aiNet.

de França, F. O. ; Von Zuben, F. J. ; de Castro, L. N. . Artificial Immune Network for Multimodal Function Optimization on Dynamic Environments. In: Genetic and Evolutionary Computation Conference, GECCO-2005, 2005, Washington. Proceedings of the Genetic and Evolutionary Computation Conference, GECCO-2005. New York : ACM Press, 2005.



# Algoritmos Imuno-Inspirados

## dcopt-aiNet

- *Artificial Immune Network for Dynamic Combinatorial Optimization;*
- Extensão da aiNet para a solução de problemas de otimização dinâmica em espaços discretos;
- Utiliza basicamente o mesmo mecanismo de busca da opt-aiNet.

de França, F.O., Gomes, L.C.T., de Castro, L.N., Von Zuben, F.J. Handling Time-Varying TSP Instances. Proceedings of the IEEE Congress on Evolutionary Computation (CEC'2006), pp. 9735-9742, Vancouver, BC, Canada, July 16-21, 2006.

# Algoritmos Imuno-Inspirados

## omni-aiNet

- *Artificial Immune Network for Omni-Optimization;*
- Extensão da aiNet para solução de problemas de otimização contínua:
  - Uniobjetivo unimodal;
  - Uniobjetivo multimodal;
  - Multi-objetivo unimodal;
  - Multi-objetivo multimodal;
- O algoritmo se adapta automaticamente ao tipo de problema.

Coelho, G. P. ; Von Zuben, F. J.. omni-aiNet: An Immune-inspired Approach for Omni Optimization. In: Fifth International Conference on Artificial Immune Systems (Icaris), 2006, Oeiras. Lecture Notes on Computer Science. Berlin Heidelberg : Springer-Verlag, 2006. v. 4163. p. 294-308.

# Algoritmos Imuno-Inspirados

## ARIA

- *Adaptive Radius Immune Algorithm;*
- Evolução da aiNet, também para problemas de agrupamento de dados;
- É capaz de considerar a densidade dos dados de entrada na determinação do raio de atuação dos anticorpos.

Bezerra, G.B., Barra, T.V., de Castro, L.N., Von Zuben, F.J. Adaptive Radius Immune Algorithm for Data Clustering. *in* Jacob, C., Pilat, M.L., Bentley, P.J., Timmis, J. (eds.) Artificial Immune Systems, Lecture Notes in Computer Science, Springer-Verlag, Berlin, vol. 3627, pp. 290-303, 2005.

# REFERÊNCIAS



# Livros – Computação Natural



- de Castro, L. N. (2006) *Fundamentals of Natural Computing: Basic Concepts, Algorithms, and Applications*, Chapman & Hall/CRC.
- de Castro, L. N. (2010) *Computação Natural – Uma Jornada Ilustrada*, Editora Livraria da Física.

# Inteligência Coletiva

Bullnheimer B., R. F. Hartl & C. Strauss (1999). A New Rank Based Version of the Ant System: A Computational Study. Central European Journal for Operations Research and Economics, 7(1):25-38, 1999.

Colorni A., M. Dorigo, F. Maffioli, V. Maniezzo, G. Righini, M. Trubian (1996). Heuristics from Nature for Hard Combinatorial Problems. International Transactions in Operational Research, 3(1):1-21.

Dorigo, M. (1992). Optimization, Learning and Natural Algorithms. PhD Thesis, Politecnico di Milano, Italy.

**Dorigo, M. & Stützle, T. (2004) Ant Colony Optimization, A Bradford Book.**

Dorigo M., V. Maniezzo & A. Colorni (1996). Ant System: Optimization by a colony of cooperating agents. IEEE Transactions on Systems, Man, and Cybernetics-Part B, 26(1):29-41

Dorigo M. & L.M. Gambardella (1997). Ant Colony System: A Cooperative Learning Approach to the Traveling Salesman Problem. IEEE Transactions on Evolutionary Computation, 1(1):53-66.

Dorigo M. & L.M. Gambardella (1997). Ant Colonies for the Traveling Salesman Problem. BioSystems, 43:73-81. Also Technical Report TR/IRIDIA/1996-3, IRIDIA, Université Libre de Bruxelles:

Gambardella L. M. and M. Dorigo (1997). HAS-SOP: An Hybrid Ant System for the Sequential Ordering Problem. Tech. Rep. No. IDSIA 97-11, IDSIA, Lugano, Switzerland.

Goss, S., S. Aron e J. L. Deneubourg (1989). Self-organized shortcuts in the Argentine ant. Naturwissenschaften, vol. 76, pp. 579-581.

# Inteligência Coletiva

Bullnheimer B., R.F. Hartl and C. Strauss (1999). An Improved Ant system Algorithm for the Vehicle Routing Problem. Annals of Operations Research (Dawid, Feichtinger and Hartl (eds.): Nonlinear Economic Dynamics and Control.

Bullnheimer B., R.F. Hartl and C. Strauss (1999). Applying the Ant System to the Vehicle Routing Problem. In: Voss S., Martello S., Osman I.H., Roucairol C. (eds.), Meta-Heuristics: Advances and Trends in Local Search Paradigms for Optimization, Kluwer:Boston.

Bullnheimer B. (1999). Ant Colony Optimization in Vehicle Routing. Doctoral thesis, University of Vienna.

Maniezzo V., A. Colorni and M. Dorigo (1994). The Ant System Applied to the Quadratic Assignment Problem. *Tech. Rep. IRIDIA/94-28*, Université Libre de Bruxelles, Belgium.

Maniezzo V., L. Muzio, A. Colorni and M. Dorigo (1994). Il sistema formiche applicato al problema dell'assegnamento quadratico. *Technical Report No. 94-058*, Politecnico di Milano, Italy, in Italian.

Maniezzo V. (1998). Exact and approximate nondeterministic tree-search procedures for the quadratic assignment problem. *Research Report CSR 98-1*, Scienze dell'Informazione, Università di Bologna, Sede di Cesena, Italy.

Taillard E. and L. M. Gambardella (1997). An Ant Approach for Structured Quadratic Assignment Problems. *2nd Metaheuristics International Conference (MIC-97)*, Sophia-Antipolis, France - July 21-24.

# Inteligência Coletiva

Costa D. and A. Hertz (1997). Ants Can Colour Graphs. *Journal of the Operational Research Society*, 48, 295-305.

de França, F. O., F. J. Von Zuben e L. N. De Castro (2004). Definition of Capacited p-Medians by a Modified Max Min Ant System with Local Search. ICONIP - 2004 11th International Conference on Neural Information Processing - SPECIAL SESSION ON ANT COLONY AND MULTI-AGENT SYSTEMS, v.3316, 2004, p.1094-110.

de França, F. O., F. J. Von Zuben e L. N. De Castro (2004). A Max Min Ant System Applied To The Capacitated Clustering Problem. 2004 IEEE Workshop on Machine Learning for Signal Processing. São Luiz, Brasil: Proceedings of the 2004 IEEE International Workshop on Machine Learning for Signal Processing. pp 755-764.

de França, F. O., F. J. Von Zuben e L. N. de Castro (2005). Max Min Ant System and Capacitated p-Medians: Extensions and Improved Solutions. *Informatica*, v.29, n.2, p.163-171.

Gambardella L. M., E. Taillard and M. Dorigo (1999). Ant Colonies for the Quadratic Assignment Problem. *Journal of the Operational Research Society*, 50:167-176.

Stützle T. and M. Dorigo (1999). ACO Algorithms for the Quadratic Assignment Problem. In D. Corne, M. Dorigo and F. Glover, editors, *New Ideas in Optimization*, McGraw-Hill.

**Bonabeau, E., Theraulaz, G. and Dorigo, M. Swarm Intelligence: From Natural to Artificial Systems, Oxford University Press, 1999.**

# Inteligência Coletiva

Schoonderwoerd R., O. Holland, J. Bruton and L. Rothkrantz (1997). Ant-based Load Balancing in Telecommunications Networks. *Adaptive Behavior*, 5(2):169-207.

Schoonderwoerd R., O. Holland and J. Bruton (1997). Ant-like Agents for Load Balancing in Telecommunications Networks. *Proceedings of Agents'97, Marina del Rey, CA, ACM Press*, 209-216.

Di Caro G. and M. Dorigo (1997). AntNet: A Mobile Agents Approach to Adaptive Routing. *Tech. Rep. IRIDIA/97-12*, Université Libre de Bruxelles, Belgium.

Di Caro G. and M. Dorigo (1998). Mobile Agents for Adaptive Routing. *Proceedings of the 31st Hawaii International Conference on System*, IEEE Computer Society Press, Los Alamitos, CA, 74-83.

Di Caro G. & Dorigo M. (1998). AntNet: Distributed Stigmergetic Control for Communications Networks. *Journal of Artificial Intelligence Research (JAIR)*, 9:317-365.

Navarro Varela G. and M.C. Sinclair (1999). Ant Colony Optimisation for Virtual-Wavelength-Path Routing and Wavelength Allocation. *Proceedings of the Congress on Evolutionary Computation (CEC'99)*, Washington DC, USA, July 1999.

Ducatelle, F., G. Di Caro and L. M. Gambardella (2005). Using Ant Agents to Combine Reactive and Proactive Strategies for Routing in Mobile Ad Hoc Networks. *International Journal of Computational Intelligence and Applications (IJCIA)*, Special Issue on Nature-Inspired Approaches to Networks and Telecommunications, Volume 5, Number 2, Pages 169-184, June 2005

# Inteligência Coletiva

Colomi A., M. Dorigo, V. Maniezzo and M. Trubian (1994). Ant system for Job-shop Scheduling. *JORBEL - Belgian Journal of Operations Research, Statistics and Computer Science*, 34(1):39-53.

Forsyth P. and A. Wren (1997). An Ant System for Bus Driver Scheduling. Presented at the *7th International Workshop on Computer-Aided Scheduling of Public Transport*, Boston, August 1997.

Eberhart, R. C. and Kennedy, J. A new optimizer using particle swarm theory. Proceedings of the Sixth International Symposium on Micromachine and Human Science, Nagoya, Japan. pp. 39-43, 1995.

Kennedy, J. and Eberhart, R. C. Particle swarm optimization. Proceedings of IEEE International Conference on Neural Networks, Piscataway, NJ. pp. 1942-1948, 1995.

**Eberhart, R. C., Shi, Y. and Kennedy, J. Swarm Intelligence, Morgan Kaufmann, 2001.**

Kannan, S., Slochanal, S. M. R., Subbaraj, P., and Padhy, N. P., "Application of particle swarm optimization technique and its variants to generation expansion planning problem," *Electric Power Systems Research*, vol. In Press, Corrected Proof 2004.

Onwubolu, G. C. and Clerc, M., "Optimal path for automated drilling operations by a new heuristic approach using particle swarm optimization," *International Journal of Production Research*, vol. 4 pp. 473-491, 2004.

# Sistemas Imunológicos Artificiais

- Burnet, F. M. (1959). The Clonal Selection Theory of Acquired Immunity. Cambridge Press.
- Jerne, N. K. (1974). Towards a network theory of the immune system. Ann. Immunol. (Inst. Pasteur), 125C, 373–389.
- Coelho, G.P.; Silva, A.E.A.; Von Zuben, F.J. (2010) An immune-inspired multi-objective approach to the reconstruction of phylogenetic trees. Neural Computing & Applications (Print) , vol. 19, pp. 1103-1132.
- de Castro, L. N. & Timmis, J. (2002), Artificial Immune Systems: A New Computational Intelligence Approach, Springer-Verlag.**
- de França, F.O.; Coelho, G.P.; Castro, P.A.D. & Von Zuben, F.J. Conceptual and Practical Aspects of the aiNet Family of Algorithms. International Journal of Natural Computing Research, v. 1, p. 1-35, 2010.
- de Castro , L. N. & Von Zuben, F. J., Learning and Optimization Using the Clonal Selection Principle , IEEE Transactions on Evolutionary Computation, Special Issue on Artificial Immune Systems, 6 (3), pp. 239-251, 2002.
- de Castro, L.N., Von Zuben, F.J. aiNet: An Artificial Immune Network for Data Analysis. in Abbass, H.A., Sarker, R.A. & Newton, C.S. (eds.) Data Mining: A Heuristic Approach, Idea Group Publishing, pp. 231-259, 2002.
- de Castro, L. N. and Timmis, J. An Artificial Immune Network for Multimodal Function Optimization. Proceedings of the IEEE Congress on Evolutionary Computation (CEC'02), Vol. 1, pp. 699-674, May, Hawaii, 2002.
- Gomes, L.C.T., de Sousa, J.S., Bezerra, G.B., de Castro, L.N., Von Zuben, F.J. Copt-aiNet and the Gene Ordering Problem. Proceedings of the Second Brazilian Workshop on Bioinformatics (WOB'2003), pp. 28-37, 2003.



# Sistemas Imunológicos Artificiais

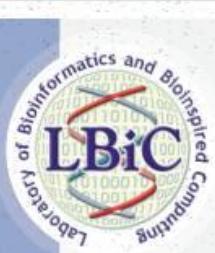
de França, F. O. ; Von Zuben, F. J. ; de Castro, L. N. . Artificial Immune Network for Multimodal Function Optimization on Dynamic Environments. In: Genetic and Evolutionary Computation Conference, GECCO-2005, 2005, Washington. Proceedings of the Genetic and Evolutionary Computation Conference, GECCO-2005. New York : ACM Press, 2005.

de França, F.O., Gomes, L.C.T., de Castro, L.N., Von Zuben, F.J. Handling Time-Varying TSP Instances. Proceedings of the IEEE Congress on Evolutionary Computation (CEC'2006), pp. 9735-9742, Vancouver, BC, Canada, July 16-21, 2006.

Coelho, G. P. ; Von Zuben, F. J.. omni-aiNet: An Immune-inspired Approach for Omni Optimization. In: Fifth International Conference on Artificial Immune Systems (Icaris), 2006, Oeiras. Lecture Notes on Computer Science. Berlin Heidelberg : Springer-Verlag, 2006. v. 4163. p. 294-308.

Bezerra, G.B., Barra, T.V., de Castro, L.N., Von Zuben, F.J. Adaptive Radius Immune Algorithm for Data Clustering. *in* Jacob, C., Pilat, M.L., Bentley, P.J., Timmis, J. (eds.) Artificial Immune Systems, Lecture Notes in Computer Science, Springer-Verlag, Berlin, vol. 3627, pp. 290-303, 2005.

Castro, P.A.D. ; de França, F.O. ; Ferreira, H.M. ; Von Zuben, F.J. Applying Bioclustering to Text Mining: An Immuno-Inspired Approach. In: International Conference on Artificial Immune System, 2007, Santos. Proc. of the 6th International Conference on Artificial Immune System, 2007.



# Sistemas Imunológicos Artificiais

Castro, P.A.D. ; França, F.O. ; Ferreira, H.M. ; Von Zuben, F.J. Applying Biclustering to Perform Collaborative Filtering. In: International Conference on Intelligent Systems Design and Applications, 2007, Rio de Janeiro. Proc. of the 7th International Conference on Intelligent Systems Design and Applications, 2007.

Castro, P.A.D. ; França, F.O. ; Ferreira, H.M. ; Von Zuben, F.J. Evaluating the Performance of a Biclustering Algorithm Applied to Collaborative Filtering A Comparative Analysis. In: International Conference on Hybrid Intelligent Systems, 2007, Kaiserslautern. Proceedings of the 7th International Conference on Hybrid Intelligent Systems, 2007.

Castro, P.A.D. & Von Zuben, F.J. Learning Ensembles of Neural Networks by Means of a Bayesian Artificial Immune System. IEEE Transactions on Neural Networks , vol. 22, pp. 304-316, 2011.

Castro, P. A. D. ; Camargo, H.A. ; Von Zuben, F.J. Evaluating the performance of a Bayesian Artificial Immune System for designing fuzzy rule bases. International Journal of Hybrid Intelligent Systems, vol. 10, pp. 43-55, 2013.

# Outros

**GLOVER, F. W. & KOCHENBERGER, G. A. (2002) Handbook of Metaheuristics, Kluwer Academic Publishers.**

GLOVER, F. & LAGUNA, M. (1997) Tabu Search, Kluwer Academic Publishers.

KIRKPATRICK, S., GERLATT, C. D. JR., & VECCHI, M. P. (1983), “Optimization by Simulated Annealing”, *Science*, 220, 671-680.

PASTI, R.; VON ZUBEN, F.J.; DE CASTRO, L.N. (2011) Ecosystems Computing. *International Journal of Natural Computing Research*, vol. 2, pp. 47-67.

**FLOREANO, D. & MATTIUSSI, C. Bio-Inspired Artificial Intelligence: Theories, Methods, and Technologies, The MIT Press, 2008.**