

Patrick de Carvalho Tavares Rezende Ferreira - RA: 175480 - EFC1

Repositório: <https://github.com/patrickctrf/EA072-Inteligencia-Artificial-IA/tree/master/EFC1>
(<https://github.com/patrickctrf/EA072-Inteligencia-Artificial-IA/tree/master/EFC1>).

In [0]:

```
%cd /content/drive/My\ Drive/PODE\ APAGAR/EA072-EF1  
  
/content/drive/My Drive/PODE APAGAR/EA072-EF1
```

Questão 3

Inicialmente, executou-se 5 vezes o código sugerido inicial a fim de verificar o desempenho da proposta. Seu desempenho foi de:

- Loss: 0.0733; Acurácia: 0.9775.

Utilizando-se o método de tentativa e erro, foi criado um script que verificava o desempenho da rede para diferentes parâmetros alterados como dropout (0.1 a 0.6), número de camadas (1 a 4 intermediárias), épocas de treinamento (4 a 8) e número de neurônios por camada (256 a 512). O script executava esta mudança de parâmetros dentro de loops "for" para executar todas as combinações possíveis e tirava também a média das múltiplas execuções com mesmos parâmetros, a fim de se obter uma média de desempenho mais confiável. Os resultados desta varredura eram salvos ao final das execuções em um arquivo "listas.txt", permitindo ao usuários verificar qual a configuração obteve melhor desempenho. Foram utilizadas 4 threads - para varredura de redes de 1 a 4 camadas - durante o treinamento, a fim de promover paralelismo e diminuir o tempo requerido, que chegava a dezenas de horas.

Analisando as configurações que obtiveram o melhor desempenho, pode-se notar que as características que o maximizavam eram: 2 camadas, 512 neurônios, taxa de dropout próxima de 0.4 e 8 épocas de treinamento.

Portanto, para a proposta final deste modelo, foi executada mais um treinamento com uso dos atributos analisados acima e os parâmetros que resultaram no melhor desempenho durante a varredura foram:

- Camadas: 2; Neurônios por camada: 512; Dropout: 0.4; Épocas: 8.

O desempenho médio obtido foi de:

- Loss: 0.0663; Acurácia: 0.9823.

Ambas as soluções consumiram um tempo de execução da ordem de poucos minutos e a diferença de desempenho foi cerca de 0,5% em ganho.

Os arquivos utilizados foram (no diretório q3):

Proposta Inicial: q3Inicial.py

Script de Varredura de parâmetros: q3.py

Proposta Final: q3Final.py

In [0]:

```
# q3Inicial.py

import tensorflow as tf
import os
mnist = tf.keras.datasets.mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0
model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(512, activation=tf.nn.relu),
    tf.keras.layers.Dropout(0.5),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)
])
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
model.fit(x_train, y_train, epochs=5)
model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_MLP.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_MLP.h5")
print("Model saved to disk")
os.getcwd()
```

```
Epoch 1/5
60000/60000 [=====] - 6s 103us/sample - los
s: 0.2698 - acc: 0.9197
Epoch 2/5
60000/60000 [=====] - 6s 101us/sample - los
s: 0.1385 - acc: 0.9579
Epoch 3/5
60000/60000 [=====] - 6s 103us/sample - los
s: 0.1080 - acc: 0.9668
Epoch 4/5
60000/60000 [=====] - 6s 101us/sample - los
s: 0.0928 - acc: 0.9710
Epoch 5/5
60000/60000 [=====] - 6s 101us/sample - los
s: 0.0821 - acc: 0.9736
10000/10000 [=====] - 1s 68us/sample - los
s: 0.0640 - acc: 0.9797
Model saved to disk
```

Out[0]:

```
'/content/drive/My Drive/PODE APAGAR/EA072-EF1'
```

In [0]:

```

#q3.py

import tensorflow as tf
import os
import threading

myMutex = threading.Lock()
value = "teste"

numeroDeNeuronios = []
numeroDeEpocas = []
numeroDeCamadas = []
numeroDeDropout = []
taxaDeAcertos = []

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
# madas.
def thread1Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
    # elo total.
    somaDasEficienciasDeCadaIteracao = 0

    # Os valores que utilizaremos para dropout variarao de 10% a 90% (instru
    # cao abaixo).
    valoresDropout = range(10, 60, 10)# Variaremos de 10% em 10%.
    valoresDropout = [i/100 for i in valoresDropout]# Converte de porcentage
    m para escala de 0 a 1.

    # Testando resultados com diferentes quantidades de epocas.
    for epocas in [8, 4]:

        # Testando resultados com diferentes quantidades de neuronios.
        for neuronios in [256, 512]:

            # So para indicar em que passo da execucao estamos.
            print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(c
            amadas) + ": " + str(neuronios) + "\n\n")

            # Este loop fica responsável por treinar com diferentes
            # "i" eh o valor a cada iteracao.
            for taxaDropout in valoresDropout:

                # Repetimos o treinamento algumas vezes para tir
                ar uma media da eficiencia
                for iteracaoMedia in range(1,4):
                    mnist = tf.keras.datasets.mnist
                    (x_train, y_train),(x_test, y_test) = mn
                    ist.load_data()
                    x_train, x_test = x_train / 255.0, x_tes
                    t / 255.0
                    model = tf.keras.models.Sequential([
                        tf.keras.layers.Flatten(),
                        tf.keras.layers.Dense(neuronios, activa
                        tion=tf.nn.relu),
                        tf.keras.layers.Dropout(taxaDropout),#
                        tf.keras.layers.Dense(10, activation=tf

```

```

.nn.softmax)

    ])
    model.compile(optimizer='adam',
                  loss='sparse_categorical_crossentropy',
                  metrics=['accuracy'])
    model.fit(x_train, y_train, epochs=epoca
s)

    value = model.evaluate(x_test, y_test)
    model_json = model.to_json()
    json_file = open("model_MLP1.json", "w")
    json_file.write(model_json)
    json_file.close()
    model.save_weights("model_MLP1.h5")
    print("Model saved to disk")
    os.getcwd()

    somaDasEficienciasDeCadaIteracao = value
[1] + somaDasEficienciasDeCadaIteracao

    myMutex.acquire()
    numeroDeNeuronios.append(neuronios)
    numeroDeEpocas.append(epocas)
    numeroDeCamadas.append(camadas)
    numeroDeDropout.append(taxaDropout)
    taxaDeAcertos.append(somaDasEficienciasDeCadaIte
racao/iteracaoMedia)

    myMutex.release()

    # Reiniciamos a soma.
    somaDasEficienciasDeCadaIteracao = 0

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
madas.
def thread2Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
elo total.
    somaDasEficienciasDeCadaIteracao = 0

    # Os valores que utilizaremos para dropout variarao de 10% a 90% (instru
cao abaixo).
    valoresDropout = range(10, 60, 10)# Variaremos de 10% em 10%.
    valoresDropout = [i/100 for i in valoresDropout]# Converte de percentage
m para escala de 0 a 1.

    # Testando resultados com diferentes quantidades de epocas.
    for epocas in [8, 4]:

        # Testando resultados com diferentes quantidades de neuronios.
        for neuronios in [256, 512]:

            # So para indicar em que passo da execucao estamos.
            print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(c
amadas) + ": " + str(neuronios) + "\n\n")

            # Este loop fica responsável por treinar com diferentes
taxas de dropout.

            # "i" eh o valor a cada iteracao.
            for taxaDropout in valoresDropout:

```

```

# Repetimos o treinamento algumas vezes para tir
ar uma media da eficiencia

for iteracaoMedia in range(1,4):
    mnist = tf.keras.datasets.mnist
    (x_train, y_train),(x_test, y_test) = mn

ist.load_data()

t / 255.0

x_train, x_test = x_train / 255.0, x_test

model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(neuronios, activa
tion=tf.nn.relu),
    Diferentes valores de dropout.
    tf.keras.layers.Dense(neuronios, activa
tion=tf.nn.relu),
    Diferentes valores de dropout.
    tf.keras.layers.Dense(10, activation=tf
.nn.softmax)

s)

value = model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_MLP2.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_MLP2.h5")
print("Model saved to disk")
os.getcwd()

somaDasEficienciasDeCadaIteracao = value

[1] + somaDasEficienciasDeCadaIteracao

myMutex.acquire()
numeroDeNeuronios.append(neuronios)
numeroDeEpocas.append(epocas)
numeroDeCamadas.append(camadas)
numeroDeDropout.append(taxaDropout)
taxaDeAcertos.append(somaDasEficienciasDeCadaIte
racao/iteracaoMedia)

myMutex.release()

# Reiniciamos a soma.
somaDasEficienciasDeCadaIteracao = 0

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
madas.
def thread3Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
elo total.
    somaDasEficienciasDeCadaIteracao = 0

```

```

# Os valores que utilizaremos para dropout variarao de 10% a 90% (instrucao abaixo).
valoresDropout = range(10, 60, 10)# Variaremos de 10% em 10%.
valoresDropout = [i/100 for i in valoresDropout]# Converte de porcentagem para escala de 0 a 1.

# Testando resultados com diferentes quantidades de epocas.
for epocas in [8, 4]:

    # Testando resultados com diferentes quantidades de neuronios.
    for neuronios in [256, 512]:

        # So para indicar em que passo da execucao estamos.
        print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(camadas) + ": " + str(neuronios) + "\n\n")

        # Este loop fica responsável por treinar com diferentes taxas de dropout.
        # "i" eh o valor a cada iteracao.
        for taxaDropout in valoresDropout:

            # Repetimos o treinamento algumas vezes para tirar uma media da eficiencia
            for iteracaoMedia in range(1,4):
                mnist = tf.keras.datasets.mnist
                (x_train, y_train),(x_test, y_test) = mnist.load_data()
                x_train, x_test = x_train / 255.0, x_test / 255.0

                model = tf.keras.models.Sequential([
                    tf.keras.layers.Flatten(),
                    tf.keras.layers.Dense(neuronios, activation=tf.nn.relu),
                    tf.keras.layers.Dropout(taxaDropout),# Diferentes valores de dropout.
                    tf.keras.layers.Dense(neuronios, activation=tf.nn.relu),
                    tf.keras.layers.Dropout(taxaDropout),# Diferentes valores de dropout.
                    tf.keras.layers.Dense(neuronios, activation=tf.nn.relu),
                    tf.keras.layers.Dropout(taxaDropout),# Diferentes valores de dropout.
                    tf.keras.layers.Dense(10, activation=tf.nn.softmax)

                ])
                model.compile(optimizer='adam',
                    loss='sparse_categorical_crossentropy',
                    metrics=['accuracy'])
                model.fit(x_train, y_train, epochs=epocas)

                value = model.evaluate(x_test, y_test)
                model_json = model.to_json()
                json_file = open("model_MLP3.json", "w")
                json_file.write(model_json)
                json_file.close()
                model.save_weights("model_MLP3.h5")
                print("Model saved to disk")
                os.getcwd()

            somaDasEficienciasDeCadaIteracao = value

```

```
[1] + somaDasEficienciasDeCadaIteracao
```

```

myMutex.acquire()
numeroDeNeuronios.append(neuronios)
numeroDeEpocas.append(epocas)
numeroDeCamadas.append(camadas)
numeroDeDropout.append(taxaDropout)
taxaDeAcertos.append(somaDasEficienciasDeCadaIte
racao/iteracaoMedia)

myMutex.release()

# Reiniciamos a soma.
somaDasEficienciasDeCadaIteracao = 0

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
madras.
def thread4Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
elo total.
    somaDasEficienciasDeCadaIteracao = 0

    # Os valores que utilizaremos para dropout variarao de 10% a 90% (instru
cao abaixo).
    valoresDropout = range(10, 60, 10)# Variaremos de 10% em 10%.
    valoresDropout = [i/100 for i in valoresDropout]# Converte de porcentaje
m para escala de 0 a 1.

    # Testando resultados com diferentes quantidades de epocas.
    for epocas in [8, 4]:

        # Testando resultados com diferentes quantidades de neuronios.
        for neuronios in [256, 512]:

            # So para indicar em que passo da execucao estamos.
            print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(c
amadas) + ": " + str(neuronios) + "\n\n")

            # Este loop fica responsável por treinar com diferentes
taxas de dropout.

            # "i" eh o valor a cada iteracao.
            for taxaDropout in valoresDropout:

                # Repetimos o treinamento algumas vezes para tir
ar uma media da eficiencia

                for iteracaoMedia in range(1,4):
                    mnist = tf.keras.datasets.mnist
                    (x_train, y_train),(x_test, y_test) = mn
ist.load_data()
                    x_train, x_test = x_train / 255.0, x_tes
t / 255.0

                    model = tf.keras.models.Sequential([
                        tf.keras.layers.Flatten(),
                        tf.keras.layers.Dense(neuronios, activa
tion=tf.nn.relu),
                        tf.keras.layers.Dropout(taxaDropout),#
                        tf.keras.layers.Dense(neuronios, activa
tion=tf.nn.relu),

```

```

    Diferentes valores de dropout.
    tion=tf.nn.relu),
    Diferentes valores de dropout.
    tion=tf.nn.relu),
    Diferentes valores de dropout.
    .nn.softmax)

s)

tf.keras.layers.Dropout(taxaDropout),#
tf.keras.layers.Dense(neuronios, activa
tf.keras.layers.Dropout(taxaDropout),#
tf.keras.layers.Dense(neuronios, activa
tf.keras.layers.Dropout(taxaDropout),#
tf.keras.layers.Dense(10, activation=tf

])
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
model.fit(x_train, y_train, epochs=epoca

value = model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_MLP4.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_MLP4.h5")
print("Model saved to disk")
os.getcwd()

somaDasEficienciasDeCadaIteracao = value

[1] + somaDasEficienciasDeCadaIteracao

myMutex.acquire()
numeroDeNeuronios.append(neuronios)
numeroDeEpocas.append(epocas)
numeroDeCamadas.append(camadas)
numeroDeDropout.append(taxaDropout)
taxaDeAcertos.append(somaDasEficienciasDeCadaIte

racao/iteracaoMedia)

myMutex.release()

# Reiniciamos a soma.
somaDasEficienciasDeCadaIteracao = 0

if __name__ == '__main__':

    camadas1 = threading.Thread(target=thread1Camadas, args=(1,))
    camadas2 = threading.Thread(target=thread2Camadas, args=(2,))
    camadas3 = threading.Thread(target=thread3Camadas, args=(3,))
    camadas4 = threading.Thread(target=thread4Camadas, args=(4,))

    camadas1.start()
    camadas2.start()
    camadas3.start()
    camadas4.start()

    try:
        camadas4.join();

```



```
except:
    pass;

try:
    camadas3.join();
except:
    pass;

try:
    camadas2.join();
except:
    pass;

try:
    camadas1.join();
except:
    pass;

listasFile = open("listasFFULLYCONNECTED.txt", "w")
listasFile.write(str(numeroDeNeuronios) + "\n")
listasFile.write(str(numeroDeEpocas) + "\n")
listasFile.write(str(numeroDeCamadas) + "\n")
listasFile.write(str(numeroDeDropout) + "\n")
listasFile.write(str(taxaDeAcertos) + "\n")
listasFile.close()
```

epocas: 8
CAMADAS4: 256

[illegible]

```
03600 - acc: 0.9808Epoch 8/8
60000/60000 [-----] - 29s 480us/sample
```

[illegible]

[illegible]

```
Epoch 6/8
60000/60000 [=====] - 26s 433us/sample -
loss: 0.0426 - acc: 0.9862
Epoch 7/8
60000/60000 [=====] - 24s 407us/sample -
loss: 0.0294 - acc: 0.9901
Epoch 8/8
60000/60000 [=====] - 29s 483us/sample -
loss: 0.0676 - acc: 0.9805
20800/60000 [=====>.....] - ETA: 17s - loss: 0.
0353 - acc: 0.9887Epoch 6/8
60000/60000 [=====] - 28s 466us/sample -
loss: 0.0511 - acc: 0.9841
48320/60000 [=====>.....] - ETA: 4s - loss: 0.0
232 - acc: 0.9922Epoch 7/8
60000/60000 [=====] - 25s 420us/sample -
loss: 0.0236 - acc: 0.9921
60000/60000 [=====] - ETA: 11s - loss: 0.
0595 - acc: 0.9814 - 27s 447us/sample - loss: 0.0373 - acc: 0.9877
Epoch 8/8
10000/10000 [=====] - 4s 375us/sample - l
oss: 0.0729 - acc: 0.9801
20000/60000 [=====>.....] - ETA: 18s - loss: 0.
0454 - acc: 0.9864Model saved to disk
53888/60000 [=====>....] - ETA: 3s - loss: 0.0
614 - acc: 0.9814Epoch 1/8
60000/60000 [=====] - 30s 493us/sample -
loss: 0.0606 - acc: 0.9817
Epoch 7/8
60000/60000 [=====] - 28s 464us/sample -
loss: 0.0472 - acc: 0.9858
31488/60000 [=====>.....] - ETA: 12s - loss: 0.
3076 - acc: 0.9106Epoch 8/8
60000/60000 [=====] - 27s 458us/sample -
loss: 0.0322 - acc: 0.9895
10000/10000 [=====] - 4s 384us/sample - l
oss: 0.0723 - acc: 0.9808
19488/60000 [=====>.....] - ETA: 19s - loss: 0.
0432 - acc: 0.9868Model saved to disk
60000/60000 [=====]24224/60000 [=====
==>.....] - 25s 413us/sample - loss: 0.2396 - acc: 0.
9302
- ETA: 16s - loss: 0.0442 - acc: 0.9870Epoch 2/8
48096/60000 [=====>.....] - ETA: 5s - loss: 0.0
543 - acc: 0.9839Epoch 1/8
60000/60000 [=====] - 29s 484us/sample -
loss: 0.0564 - acc: 0.9833
Epoch 8/8
60000/60000 [=====] - 28s 472us/sample -
loss: 0.0457 - acc: 0.9860
10000/10000 [=====] - 4s 385us/sample - l
oss: 0.0767 - acc: 0.9823
29312/60000 [=====>.....] - ETA: 14s - loss: 0.
0480 - acc: 0.9863Model saved to disk
37056/60000 [=====>.....] - ETA: 10s - loss: 0.
0472 - acc: 0.9868Epoch 1/8
60000/60000 [=====] - 25s 417us/sample -
loss: 0.1027 - acc: 0.9683
52416/60000 [=====>....]37376/60000 [=====
=====>.....] - ETA: 3s - loss: 0.2329 - acc: 0.9288 - ET
A: 10s - loss: 0.0471 - acc: 0.9868Epoch 3/8
```

[illegible]

[illegible]


```
loss: 0.1132 - acc: 0.9664
Epoch 3/8
60000/60000 [=====] - 27s 458us/sample -
loss: 0.0408 - acc: 0.9875
60000/60000 [=====] - 29s 476us/sample -
loss: 0.0537 - acc: 0.9843
43232/60000 [=====>.....] - ETA: 6s - loss: 0.0
836 - acc: 0.9732Epoch 8/8
60000/60000 [=====] - 27s 445us/sample -
loss: 0.2484 - acc: 0.9248
Epoch 2/8
10000/10000 [=====] - 4s 371us/sample - l
oss: 0.0868 - acc: 0.9798
2656/60000 [>.....] - ETA: 30s - loss: 0.
0440 - acc: 0.9880Model saved to disk
11552/60000 [=====>.....] - ETA: 20s - loss: 0.
1213 - acc: 0.9619Epoch 1/8
60000/60000 [=====] - 24s 405us/sample -
loss: 0.0831 - acc: 0.9736
Epoch 4/8
60000/60000 [=====] - 27s 447us/sample -
loss: 0.1159 - acc: 0.9639
Epoch 3/846304/60000 [=====>.....] - ETA: 6s -
loss: 0.2920 - acc: 0.9104
60000/60000 [=====] - 29s 484us/sample -
loss: 0.0479 - acc: 0.9863
60000/60000 [=====] - 25s 418us/sample -
loss: 0.0653 - acc: 0.9794
Epoch 5/8
10000/10000 [=====] - 4s 363us/sample - l
oss: 0.0785 - acc: 0.9799
60000/60000 [=====] - 28s 468us/sample -
loss: 0.2632 - acc: 0.9195
14688/60000 [=====>.....] - ETA: 19s - loss: 0.
0876 - acc: 0.9732Epoch 2/8
15776/60000 [=====>.....] - ETA: 18s - loss: 0.
0869 - acc: 0.9730Model saved to disk
19200/60000 [=====>.....] - ETA: 14s - loss: 0.
0521 - acc: 0.9834Epoch 1/8
60000/60000 [=====] - 25s 424us/sample -
loss: 0.0923 - acc: 0.9713
44096/60000 [=====>.....] - ETA: 6s - loss: 0.1
359 - acc: 0.9593Epoch 4/8
60000/60000 [=====] 6624/60000 [==
>.....] - 24s 403us/sample - loss: 0.0542 -
acc: 0.9826
- ETA: 25s - loss: 0.0616 - acc: 0.9802Epoch 6/8
60000/60000 [=====] - 27s 449us/sample -
loss: 0.1332 - acc: 0.9600
10432/60000 [=====>.....] - ETA: 21s - loss: 0.
0445 - acc: 0.9868Epoch 3/8
17920/60000 [=====>.....]60000/60000 [=====
=====] - ETA: 19s - loss: 0.1048 - acc: 0.9670 - 3
0s 503us/sample - loss: 0.2882 - acc: 0.9119
30560/60000 [=====>.....] - ETA: 12s - loss: 0.
0452 - acc: 0.9858Epoch 2/8
60000/60000 [=====] - 27s 445us/sample -
loss: 0.0739 - acc: 0.9762
41408/60000 [=====>.....] - ETA: 8s - loss: 0.1
045 - acc: 0.9689Epoch 5/8
60000/60000 [=====] - 25s 418us/sample -
```

◀ ▶ ▼

In [0]:

```
# q3Final.py

import tensorflow as tf
import os
mnist = tf.keras.datasets.mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0
model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(512, activation=tf.nn.relu),
    tf.keras.layers.Dropout(0.3),
    tf.keras.layers.Dense(512, activation=tf.nn.relu),
    tf.keras.layers.Dropout(0.4),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)
])
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
model.fit(x_train, y_train, epochs=8)
model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_MLP.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_MLP.h5")
print("Model saved to disk")
os.getcwd()
```

```
Epoch 1/8
60000/60000 [=====] - 5s 84us/sample - los
s: 0.2446 - acc: 0.9246
Epoch 2/8
60000/60000 [=====] - 5s 83us/sample - los
s: 0.1283 - acc: 0.9617
Epoch 3/8
60000/60000 [=====] - 5s 82us/sample - los
s: 0.1008 - acc: 0.9691
Epoch 4/8
60000/60000 [=====] - 5s 82us/sample - los
s: 0.0869 - acc: 0.9737
Epoch 5/8
60000/60000 [=====] - 5s 83us/sample - los
s: 0.0779 - acc: 0.9765
Epoch 6/8
60000/60000 [=====] - 5s 82us/sample - los
s: 0.0712 - acc: 0.9787
Epoch 7/8
60000/60000 [=====] - 5s 83us/sample - los
s: 0.0653 - acc: 0.9803
Epoch 8/8
60000/60000 [=====] - 5s 83us/sample - los
s: 0.0618 - acc: 0.9819
10000/10000 [=====] - 1s 58us/sample - los
s: 0.0669 - acc: 0.9823
Model saved to disk
```

Out[0]:

'/content'

Questão 4

Inicialmente, executou-se 5 vezes o código sugerido inicial a fim de verificar o desempenho da proposta. Seu desempenho foi de:

- Loss: 0.0260; Acurácia: 0.9909.

Utilizando-se o método de tentativa e erro, foi criado um script que verificava o desempenho da rede para diferentes parâmetros alterados como dropout (0.1 a 0.6), número de filtros (32 a 64), épocas de treinamento (2 a 6) e formato dos kernel utilizados (2x2 ou 3x3). O script executava esta mudança de parâmetros dentro de loops "for" para executar todas as combinações possíveis e tirava também a média das múltiplas execuções com mesmos parâmetros, a fim de se obter uma média de desempenho mais confiável. Os resultados desta varredura eram salvos ao final das execuções em um arquivo "listas.txt", permitindo ao usuários verificar qual a configuração obteve melhor desempenho. Foram utilizadas 4 threads - para varredura de redes de 1 a 4 camadas - durante o treinamento, a fim de promover paralelismo e diminuir o tempo requerido, que era ainda maior que o demandado para a questão 1. Verificou-se que com 6 épocas de treinamento o resultado era levemente melhorado, mas não significativamente. A variação das demais grandezas fazia o desempenho diminuir nos testes. Então, após a varredura, foi realizado mais uma tentativa de treinamento com adição de uma camada convolucional e dropout de 0.3, o que elevou os resultados e nos trouxe à proposta final de código para esta questão.

Através da varredura, foi possível perceber que as alterações que implicavam em aumento de desempenho eram: Maior número de filtros, 2 camadas convolucionais, taxa de dropout próxima de 0.3 e kernel 3x3 (com max pool 2x2).

Portanto, para a proposta final deste modelo, os parâmetros alterados que resultaram no melhor desempenho durante a varredura foram:

- Adição de duas camadas convolucionais com kernel 3x3 (seguida de uma max pool em 2x2) após a saída da primeira layer de max pool; 8 épocas de treinamento. Camadas convolucionais todas com 512 filtros e dropout de 0,3. Os demais parâmetros foram mantidos por não apresentar vantagem média significativa.

O desempenho médio obtido foi de:

- Loss: 0.0190; Acurácia: 0.9935.

Ambas as soluções consumiram um tempo de execução da ordem de poucos minutos e a diferença de desempenho foi cerca de 0,22% em ganho.

Os arquivos utilizados foram (no diretório q2):

Proposta Inicial: q4Inicial.py

Script de Varredura de parâmetros: q4.py

Proposta Final: q4Final.py

Comparação entre ELM, MLP e CNN

Desempenho:

- ELM: 91,09%
- MLP: 98,23%

- CNN: 99,35%

Nota-se claramente que a CNN apresenta o melhor desempenho dentre as 3 melhores técnicas utilizadas. Porém, o processo de treinamento para otimização desta toma dezenas de horas, enquanto que a ELM requer apenas alguns minutos para ser ajustada e ficar cerca de 8% abaixo em desempenho. Logo, se

In [0]:

```
# q4Inicial.py

import tensorflow as tf
import os
mnist = tf.keras.datasets.mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()
# reshape to be [samples][width][height][pixels]
x_train = x_train.reshape(x_train.shape[0], 28, 28, 1)
x_test = x_test.reshape(x_test.shape[0], 28, 28, 1)
x_train, x_test = x_train / 255.0, x_test / 255.0
model = tf.keras.models.Sequential()
model.add(tf.keras.layers.Conv2D(32, kernel_size=(3, 3),
    activation='relu',
    input_shape=(28, 28, 1)))
model.add(tf.keras.layers.Conv2D(64, (3, 3), activation='relu'))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
model.add(tf.keras.layers.Dropout(0.25))
model.add(tf.keras.layers.Flatten())
model.add(tf.keras.layers.Dense(128, activation='relu'))
model.add(tf.keras.layers.Dropout(0.5))
model.add(tf.keras.layers.Dense(10, activation='softmax'))
model.compile(optimizer='adam',
    loss='sparse_categorical_crossentropy',
    metrics=['accuracy'])
model.fit(x_train, y_train, epochs=5)
model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_CNN.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_CNN.h5")
print("Model saved to disk")
os.getcwd()
```

Epoch 1/5

```
60000/60000 [=====] - 16s 268us/sample - loss: 0.2004 - acc: 0.9403
```

Epoch 2/5

```
60000/60000 [=====] - 15s 256us/sample - loss: 0.0851 - acc: 0.9741
```

Epoch 3/5

```
60000/60000 [=====] - 15s 251us/sample - loss: 0.0628 - acc: 0.9809
```

Epoch 4/5

```
60000/60000 [=====] - 15s 252us/sample - loss: 0.0532 - acc: 0.9837
```

Epoch 5/5

```
60000/60000 [=====] - 15s 249us/sample - loss: 0.0461 - acc: 0.9857
```

```
10000/10000 [=====] - 1s 114us/sample - loss: 0.0294 - acc: 0.9906
```

Model saved to disk

Out[0]:

```
'/content/drive/My Drive/PODE APAGAR/EA072-EF1'
```

In [0]:

```

# q4.py

import tensorflow as tf
import os
import threading

myMutex = threading.Lock()
value = "teste"

numeroDeNeuronios = []
numeroDeEpocas = []
numeroDeCamadas = []
numeroDeDropout = []
taxaDeAcertos = []

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
# madas.
def thread1Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
    # elo total.
    somaDasEficienciasDeCadaIteracao = 0

    # Os valores que utilizaremos para dropout variarao de 10% a 90% (instru
    # cao abaixo).
    valoresDropout = range(10, 40, 10)# Variaremos de 10% em 10%.
    valoresDropout = [i/100 for i in valoresDropout]# Converte de porcentage
    m para escala de 0 a 1.

    # Testando resultados com diferentes quantidades de epocas.
    for epocas in [2, 6]:

        # Testando resultados com diferentes quantidades de filtros.
        for filtros in [32, 64]:

            # So para indicar em que passo da execucao estamos.
            print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(c
            amadas) + ": " + str(filtros) + "\n\n")

            # Este loop fica responsável por treinar com diferentes
            # taxas de dropout.
            # "i" eh o valor a cada iteracao.
            for taxaDropout in valoresDropout:

                # Repetimos o treinamento algumas vezes para tir
                ar uma media da eficiencia
                for iteracaoMedia in range(1,3):
                    mnist = tf.keras.datasets.mnist
                    (x_train, y_train),(x_test, y_test) = mn
                    ist.load_data()
                    # reshape to be [samples][width][height]
                    [pixels]
                    x_train = x_train.reshape(x_train.shape[
                    0], 28, 28, 1)
                    x_test = x_test.reshape(x_test.shape[0],
                    28, 28, 1)
                    x_train, x_test = x_train / 255.0, x_tes
                    t / 255.0
                    model = tf.keras.models.Sequential()

```



```

, kernel_size=(3, 3),
*2, (3, 3), activation='relu'))
ool_size=(2, 2))
opout))

ivation='relu'))
opout))
vation='softmax'))

s)

model.add(tf.keras.layers.Conv2D(filtros
    activation='relu',
    input_shape=(28, 28, 1)))
model.add(tf.keras.layers.Conv2D(filtros
model.add(tf.keras.layers.MaxPooling2D(p
model.add(tf.keras.layers.Dropout(taxaDr
opout))

model.add(tf.keras.layers.Flatten())
model.add(tf.keras.layers.Dense(128, act
model.add(tf.keras.layers.Dropout(taxaDr
opout))

model.add(tf.keras.layers.Dense(10, acti
model.compile(optimizer='adam',
    loss='sparse_categorical_crossentropy',
    metrics=['accuracy'])
model.fit(x_train, y_train, epochs=epoca
s)

value = model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_CNN1.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_CNN1.h5")
print("Model saved to disk")
os.getcwd()

somaDasEficienciasDeCadaIteracao = value
[1] + somaDasEficienciasDeCadaIteracao

myMutex.acquire()
numeroDeNeuronios.append(filtros)
numeroDeEpocas.append(epocas)
numeroDeCamadas.append(camadas)
numeroDeDropout.append(taxaDropout)
taxaDeAcertos.append(somaDasEficienciasDeCadaIte
racao/iteracaoMedia)

myMutex.release()

# Reiniciamos a soma.
somaDasEficienciasDeCadaIteracao = 0

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
madas.
def thread2Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
elo total.
    somaDasEficienciasDeCadaIteracao = 0

    # Os valores que utilizaremos para dropout variarao de 10% a 90% (instru
cao abaixo).
    valoresDropout = range(10, 40, 10)# Variaremos de 10% em 10%.
    valoresDropout = [i/100 for i in valoresDropout]# Converte de porcentage
m para escala de 0 a 1.

```

```

# Testando resultados com diferentes quantidades de epocas.
for epocas in [2, 6]:

    # Testando resultados com diferentes quantidades de filtros.
    for filtros in [32, 64]:

        # So para indicar em que passo da execucao estamos.
        print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(camadas) + ": " + str(filtros) + "\n\n")

        # Este loop fica responsável por treinar com diferentes
        # "i" eh o valor a cada iteracao.
        for taxaDropout in valoresDropout:

            # Repetimos o treinamento algumas vezes para tirar uma media da eficiencia
            for iteracaoMedia in range(1,3):
                mnist = tf.keras.datasets.mnist
                (x_train, y_train),(x_test, y_test) = mnist.load_data()

                # reshape to be [samples][width][height][pixels]
                x_train = x_train.reshape(x_train.shape[0], 28, 28, 1)
                x_test = x_test.reshape(x_test.shape[0], 28, 28, 1)
                x_train, x_test = x_train / 255.0, x_test / 255.0

                model = tf.keras.models.Sequential()
                model.add(tf.keras.layers.Conv2D(filtros, kernel_size=(2, 2),
                activation='relu',
                input_shape=(28, 28, 1)))
                model.add(tf.keras.layers.Conv2D(filtros*2, (3, 3), activation='relu'))
                model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
                model.add(tf.keras.layers.Conv2D(filtros*2, (3, 3), activation='relu'))
                model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
                model.add(tf.keras.layers.Dropout(taxaDropout))
                model.add(tf.keras.layers.Flatten())
                model.add(tf.keras.layers.Dense(128, activation='relu'))
                model.add(tf.keras.layers.Dropout(taxaDropout))
                model.add(tf.keras.layers.Dense(10, activation='softmax'))

                model.compile(optimizer='adam',
                    loss='sparse_categorical_crossentropy',
                    metrics=['accuracy'])
                model.fit(x_train, y_train, epochs=epocas)

                value = model.evaluate(x_test, y_test)
                model_json = model.to_json()
                json_file = open("model_CNN2.json", "w")
                json_file.write(model_json)

```

```

        json_file.close()
        model.save_weights("model_CNN2.h5")
        print("Model saved to disk")
        os.getcwd()

        somaDasEficienciasDeCadaIteracao = value
[1] + somaDasEficienciasDeCadaIteracao

        myMutex.acquire()
        numeroDeNeuronios.append(filtros)
        numeroDeEpocas.append(epocas)
        numeroDeCamadas.append(camadas)
        numeroDeDropout.append(taxaDropout)
        taxaDeAcertos.append(somaDasEficienciasDeCadaIte
        racao/iteracaoMedia)

        myMutex.release()

        # Reiniciamos a soma.
        somaDasEficienciasDeCadaIteracao = 0

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
# madas.
def thread3Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
    # elo total.
    somaDasEficienciasDeCadaIteracao = 0

    # Os valores que utilizaremos para dropout variarao de 10% a 90% (instru
    # cao abaixo).
    valoresDropout = range(10, 40, 10)# Variaremos de 10% em 10%.
    valoresDropout = [i/100 for i in valoresDropout]# Converte de porcentage
    m para escala de 0 a 1.

    # Testando resultados com diferentes quantidades de epocas.
    for epocas in [2, 6]:

        # Testando resultados com diferentes quantidades de filtros.
        for filtros in [32, 64]:

            # So para indicar em que passo da execucao estamos.
            print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(c
            amadas) + ": " + str(filtros) + "\n\n")

            # Este loop fica responsável por treinar com diferentes
            # taxas de dropout.
            # "i" eh o valor a cada iteracao.
            for taxaDropout in valoresDropout:

                # Repetimos o treinamento algumas vezes para tir
                ar uma media da eficiencia
                for iteracaoMedia in range(1,3):
                    mnist = tf.keras.datasets.mnist
                    (x_train, y_train),(x_test, y_test) = mn
                    ist.load_data()

                    # reshape to be [samples][width][height]
                    [pixels]
                    x_train = x_train.reshape(x_train.shape[

```

```

0], 28, 28, 1)

28, 28, 1)

t / 255.0

, kernel_size=(3, 3),

*2, (2, 2), activation='relu'))

ool_size=(2, 2)))

opout))

ivation='relu'))

opout))

vation='softmax'))

s)

value = model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_CNN3.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_CNN3.h5")
print("Model saved to disk")
os.getcwd()

somaDasEficienciasDeCadaIteracao = value

[1] + somaDasEficienciasDeCadaIteracao

myMutex.acquire()
numeroDeNeuronios.append(filtros)
numeroDeEpocas.append(epocas)
numeroDeCamadas.append(camadas)
numeroDeDropout.append(taxaDropout)
taxaDeAcertos.append(somaDasEficienciasDeCadaIte

racao/iteracaoMedia)

myMutex.release()

# Reiniciamos a soma.
somaDasEficienciasDeCadaIteracao = 0

# Vamos colocar uma thread para treinar cada rede com um numero especifico de ca
madas.
def thread4Camadas(camadas):

    # Para tirar a media das iteracoes, somaremos todas aqui e dividiremos p
elo total.
    somaDasEficienciasDeCadaIteracao = 0

```

```

# Os valores que utilizaremos para dropout variarao de 10% a 90% (instrucao abaixo).
valoresDropout = range(10, 40, 10)# Variaremos de 10% em 10%.
valoresDropout = [i/100 for i in valoresDropout]# Converte de porcentagem para escala de 0 a 1.

# Testando resultados com diferentes quantidades de epocas.
for epocas in [2, 6]:

    # Testando resultados com diferentes quantidades de filtros.
    for filtros in [32, 64]:

        # So para indicar em que passo da execucao estamos.
        print("\n\nepocas: " + str(epocas) + "\nCAMADAS" + str(camadas) + ": " + str(filtros) + "\n\n")

        # Este loop fica responsável por treinar com diferentes taxas de dropout.
        # "i" eh o valor a cada iteracao.
        for taxaDropout in valoresDropout:

            # Repetimos o treinamento algumas vezes para tirar uma media da eficiencia
            for iteracaoMedia in range(1,3):
                mnist = tf.keras.datasets.mnist
                (x_train, y_train),(x_test, y_test) = mnist.load_data()
                # reshape to be [samples][width][height][pixels]
                x_train = x_train.reshape(x_train.shape[0], 28, 28, 1)
                x_test = x_test.reshape(x_test.shape[0], 28, 28, 1)
                x_train, x_test = x_train / 255.0, x_test / 255.0

                model = tf.keras.models.Sequential()
                model.add(tf.keras.layers.Conv2D(filtros, kernel_size=(3, 3),
                    activation='relu', input_shape=(28, 28, 1)))
                model.add(tf.keras.layers.Conv2D(filtros*2, (3, 3), activation='relu'))
                model.add(tf.keras.layers.MaxPooling2D(pool_size=(3, 3)))
                model.add(tf.keras.layers.Conv2D(filtros*2, (3, 3), activation='relu'))
                model.add(tf.keras.layers.MaxPooling2D(pool_size=(3, 3)))
                model.add(tf.keras.layers.Dropout(taxaDropout))
                model.add(tf.keras.layers.Flatten())
                model.add(tf.keras.layers.Dense(128, activation='relu'))
                model.add(tf.keras.layers.Dropout(taxaDropout))
                model.add(tf.keras.layers.Dense(10, activation='softmax'))

                model.compile(optimizer='adam', loss='sparse_categorical_crossentropy', metrics=['accuracy'])

```

```

s)
    model.fit(x_train, y_train, epochs=epoca

value = model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_CNN4.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_CNN4.h5")
print("Model saved to disk")
os.getcwd()

somaDasEficienciasDeCadaIteracao = value
[1] + somaDasEficienciasDeCadaIteracao

myMutex.acquire()
numeroDeNeuronios.append(filtros)
numeroDeEpocas.append(epocas)
numeroDeCamadas.append(camadas)
numeroDeDropout.append(taxaDropout)
taxaDeAcertos.append(somaDasEficienciasDeCadaIte
racao/iteracaoMedia)

myMutex.release()

# Reiniciamos a soma.
somaDasEficienciasDeCadaIteracao = 0

if __name__ == '__main__':

    camadas1 = threading.Thread(target=thread1Camadas, args=(1,))
    camadas2 = threading.Thread(target=thread2Camadas, args=(2,))
    camadas3 = threading.Thread(target=thread3Camadas, args=(3,))
    camadas4 = threading.Thread(target=thread4Camadas, args=(4,))

    camadas1.start()
    camadas2.start()
    camadas3.start()
    camadas4.start()

    try:
        camadas4.join();
    except:
        pass;

    try:
        camadas3.join();
    except:
        pass;

    try:
        camadas2.join();
    except:
        pass;

    try:
        camadas1.join();

```

```
except:
    pass;

listasFile = open("listasCONV.txt", "w")
listasFile.write(str(numeroDeNeuronios) + "\n")
listasFile.write(str(numeroDeEpocas) + "\n")
listasFile.write(str(numeroDeCamadas) + "\n")
listasFile.write(str(numeroDeDropout) + "\n")
listasFile.write(str(taxaDeAcertos) + "\n")
listasFile.close()
```

epocas: 2
CAMADAS1: 32

```
epocas: 2
CAMADAS2: 32
```

epocas: 2
CAMADAS3: 32

epocas: 2
CAMADAS4: 32

[illegible]

[illegible]

```

10000/10000 [=====] 8864/60000 [====
>.....] - 5s 490us/sample - loss: 0.0226 - ac
c: 0.9920
10176/60000 [====>.....] - ETA: 30s - loss: 0.
4048 - acc: 0.8755Model saved to disk
16736/60000 [=====>.....] - ETA: 22s - loss: 0.
3068 - acc: 0.9071Epoch 1/2
3808/60000 [>.....] - ETA: 41s - loss: 0.
6087 - acc: 0.8072Epoch 1/2
23264/60000 [=====>.....] - ETA: 19s - loss: 0
2558 - acc: 0.9233Epoch 1/2
60000/60000 [=====] - 44s 727us/sample -
loss: 0.1517 - acc: 0.9544
42400/60000 [=====>.....] - ETA: 14s - loss: 0.
1568 - acc: 0.9520Epoch 2/2
60000/60000 [=====]17280/60000 [=====
>.....] - 50s 831us/sample - loss: 0.1301 - acc:
0.9600
- ETA: 37s - loss: 0.0582 - acc: 0.9823Epoch 2/2
60000/60000 [=====] - 53s 879us/sample -
loss: 0.1961 - acc: 0.9370
24256/60000 [=====>.....] - ETA: 30s - loss: 0.
0578 - acc: 0.9824
60000/60000 [=====] - 53s 886us/sample -
loss: 0.1372 - acc: 0.9575
1120/60000 [.....] - ETA: 53s - loss: 0.
0643 - acc: 0.9812Epoch 2/2
60000/60000 [=====] - 51s 858us/sample -
loss: 0.0561 - acc: 0.9828
10000/10000 [=====] - 7s 663us/sample - l
oss: 0.0444 - acc: 0.9855
44224/60000 [=====>.....] - ETA: 13s - loss: 0.
0500 - acc: 0.9847Model saved to disk
51232/60000 [=====>.....] - ETA: 7s - loss: 0.0
617 - acc: 0.9809Epoch 1/2
60000/60000 [=====] - 49s 811us/sample -
loss: 0.0476 - acc: 0.9852
60000/60000 [=====] - 49s 812us/sample -
loss: 0.0613 - acc: 0.9812
10000/10000 [=====] - 7s 687us/sample - l
oss: 0.0332 - acc: 0.9880
60000/60000 [=====] - 50s 826us/sample -
loss: 0.0504 - acc: 0.9844
- ETA: 36s - loss: 0.3671 - acc: 0.8889 2688/10000 [=====
>.....] - ETA: 4s - loss: 0.0465 - acc: 0.9855Mod
el saved to disk
10000/10000 [=====]16960/60000 [=====
>.....] - 5s 456us/sample - loss: 0.0287 - acc:
0.9910
18208/60000 [=====>.....] - ETA: 27s - loss: 0.
2861 - acc: 0.9138Model saved to disk
9856/10000 [=====>.] - ETA: 0s - loss: 0.0
253 - acc: 0.9915
10000/10000 [=====] - 4s 429us/sample - l
oss: 0.0251 - acc: 0.9916
992/60000 [.....] - ETA: 54s - loss: 1.
2646 - acc: 0.5978Model saved to disk
8960/60000 [==>.....] - ETA: 30s - loss: 0.
3878 - acc: 0.8802Epoch 1/2

```

```
10528/60000 [====>.....]30944/60000 [=====
====>.....] - ETA: 28s - loss: 0.3538 - acc: 0.8903 - E
TA: 17s - loss: 0.2135 - acc: 0.9359Epoch 1/2
60000/60000 [=====] - 43s 716us/sample -
loss: 0.1497 - acc: 0.9546
Epoch 2/2
60000/60000 [=====] - 48s 803us/sample -
loss: 0.1308 - acc: 0.9597
22080/60000 [=====>.....] - ETA: 31s - loss: 0.
0559 - acc: 0.9824Epoch 2/2
60000/60000 [=====] - 52s 870us/sample -
loss: 0.1849 - acc: 0.9408
59712/60000 [=====>.....] - ETA: 0s - loss: 0.1
432 - acc: 0.9552Epoch 2/2
60000/60000 [=====] - 52s 861us/sample -
loss: 0.1431 - acc: 0.9552
384/60000 [.....] - ETA: 43s - loss: 0.
0399 - acc: 0.9870Epoch 2/2
25632/60000 [=====>.....]60000/60000 [=====
=====] - ETA: 30s - loss: 0.0634 - acc: 0.9808 - 5
0s 833us/sample - loss: 0.0557 - acc: 0.9826
10000/10000 [=====] - 7s 692us/sample - l
oss: 0.0404 - acc: 0.9863
46592/60000 [=====>.....]35456/60000 [=====
=====>.....] - ETA: 11s - loss: 0.0487 - acc: 0.9851 - E
TA: 20s - loss: 0.0542 - acc: 0.9831Model saved to disk
40320/60000 [=====>.....] - ETA: 16s - loss: 0.
0610 - acc: 0.9809Epoch 1/2
60000/60000 [=====] - 51s 849us/sample -
loss: 0.0487 - acc: 0.9850
10000/10000 [=====] - 7s 680us/sample - l
oss: 0.0326 - acc: 0.9892
18240/60000 [=====>.....] - ETA: 34s - loss: 0.
2834 - acc: 0.9126Model saved to disk
60000/60000 [=====] - 50s 833us/sample -
loss: 0.0607 - acc: 0.9815
60000/60000 [=====] - 50s 835us/sample -
loss: 0.0509 - acc: 0.9845
8288/10000 [=====>.....] - ETA: 0s - loss: 0.0
270 - acc: 0.9906Epoch 1/2
10000/10000 [=====] - 5s 457us/sample - l
oss: 0.0252 - acc: 0.9914
10000/10000 [=====] - 5s 486us/sample - l
oss: 0.0356 - acc: 0.9888
29696/60000 [=====>.....]
31072/60000 [=====>.....] - ETA: 20s - loss: 0.
2140 - acc: 0.9350Model saved to disk
41152/60000 [=====>.....] - ETA: 12s - loss: 0.
1846 - acc: 0.9438Epoch 1/2
416/60000 [.....] - ETA: 2:32 - loss:
2.2737 - acc: 0.1514
60000/60000 [=====] - 43s 712us/sample -
loss: 0.1542 - acc: 0.9530
30432/60000 [=====>.....] - ETA: 22s - loss: 0.
2103 - acc: 0.9360Epoch 2/2
60000/60000 [=====] - 49s 809us/sample -
loss: 0.1484 - acc: 0.9548
45248/60000 [=====>.....] - ETA: 13s - loss: 0.
2581 - acc: 0.9160
60000/60000 [=====] - 53s 890us/sample -
loss: 0.2196 - acc: 0.9287
```

epocas: 2
CAMADAS3: 64

[illegible]

[illegible]

Epoch 2/2

```
5856/60000 [=>.....] - ETA: 1:17 - loss:
```

0.0470 - acc: 0.984

[illegible]

Buffered data was truncated after reaching the output size limit.

In [0]:

```
# q4Final.py
import tensorflow as tf
import os
mnist = tf.keras.datasets.mnist
(x_train, y_train),(x_test, y_test) = mnist.load_data()
# reshape to be [samples][width][height][pixels]
x_train = x_train.reshape(x_train.shape[0], 28, 28, 1)
x_test = x_test.reshape(x_test.shape[0], 28, 28, 1)
x_train, x_test = x_train / 255.0, x_test / 255.0
model = tf.keras.models.Sequential()
model.add(tf.keras.layers.Conv2D(32, kernel_size=(3, 3),
    activation='relu',
    input_shape=(28, 28, 1)))
model.add(tf.keras.layers.Conv2D(512, (3, 3), activation='relu'))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
model.add(tf.keras.layers.Dropout(0.3))
model.add(tf.keras.layers.Conv2D(512, (3, 3), activation='relu'))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
model.add(tf.keras.layers.Dropout(0.3))
model.add(tf.keras.layers.Conv2D(512, (3, 3), activation='relu'))
model.add(tf.keras.layers.MaxPooling2D(pool_size=(2, 2)))
model.add(tf.keras.layers.Dropout(0.3))
model.add(tf.keras.layers.Flatten())
model.add(tf.keras.layers.Dense(128, activation='relu'))
model.add(tf.keras.layers.Dropout(0.5))
model.add(tf.keras.layers.Dense(10, activation='softmax'))
model.compile(optimizer='adam',
    loss='sparse_categorical_crossentropy',
    metrics=['accuracy'])
model.fit(x_train, y_train, epochs=10)
model.evaluate(x_test, y_test)
model_json = model.to_json()
json_file = open("model_CNN.json", "w")
json_file.write(model_json)
json_file.close()
model.save_weights("model_CNN.h5")
print("Model saved to disk")
os.getcwd()
```



```
Epoch 1/10
60000/60000 [=====] - 79s 1ms/sample - los
s: 0.2189 - acc: 0.9315
Epoch 2/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0785 - acc: 0.9787
Epoch 3/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0625 - acc: 0.9830
Epoch 4/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0532 - acc: 0.9855
Epoch 5/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0457 - acc: 0.9871
Epoch 6/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0438 - acc: 0.9879
Epoch 7/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0376 - acc: 0.9899
Epoch 8/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0353 - acc: 0.9904
Epoch 9/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0340 - acc: 0.9907
Epoch 10/10
60000/60000 [=====] - 78s 1ms/sample - los
s: 0.0335 - acc: 0.9909
10000/10000 [=====] - 4s 428us/sample - los
s: 0.0298 - acc: 0.9935
Model saved to disk
```

Out[0]:

'/content'